华南理工大学
South China University of Technology

运维数字员工

OpsWarden

课题六：运维数字员工的建设

组长：廖晨扬
组员：吴雨彤、丁其彬
班级：2023级计算机科学与技术2班

壹.为什么做

贰.做了什么

叁.做出的亮点

为什么企业要做运维数字员工？

对标腾讯"小Q同学"、讯飞"飞飞助手"等企业自研 RAG 知识库，把内部运维知识统一管理起来。

- 企业运维同学每天在重复回答同样的问题

1.人工响应慢，排队等回复

2.大量重复咨询，人工成本高

3.知识分散在聊天记录，难复用

三人团队分工

AI + 后端 + 部署各司其职，从模型到上线

廖晨扬

组长

1.AI 架构设计

2.RAG 设计

3.前端设计

4.敏捷开发统筹

吴雨彤

组员

1.后端接口

2.账号登录

3.工单模块

4.数据库设计

丁其彬

组员

1.Docker 容器化

2.云服务器部署

3.部署本地大模型

4.尝试申请域名

贰·做了什么——一条请求是如何流动的

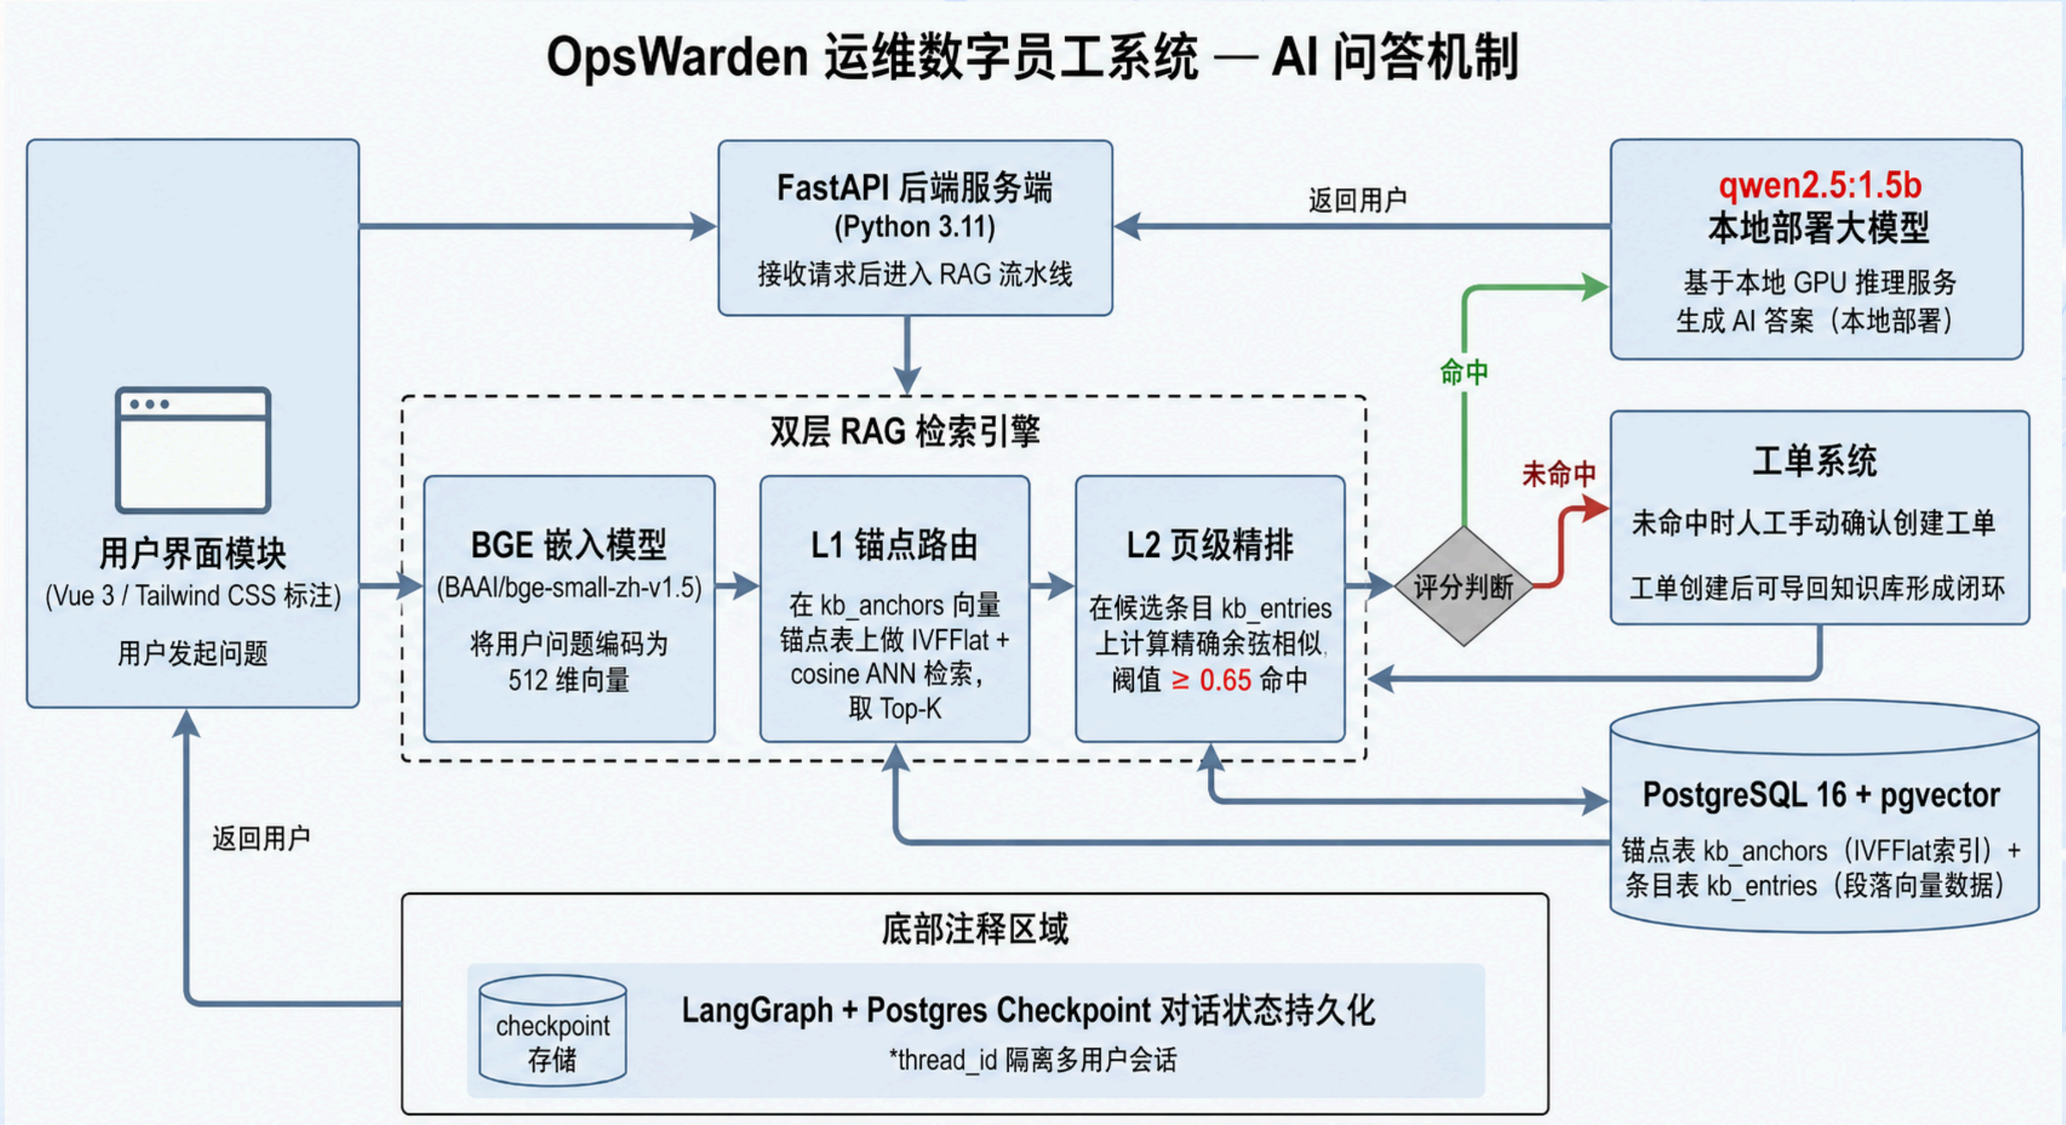

贰·做了什么—RAG核心：GridTrace— Trace the path through the grid.

South China University of Technology

Cornell University

arXiv > cs > arXiv:2402.00751

Computer Science > Machine Learning

[Submitted on 1 Feb 2024 (v1), last revised 29 Sep 2025 (this version, v2)]

Fast Exact Unlearning for In-Context Learning Data for LLMs

Andrei I. Muresanu, Anvith Thudi, Michael R. Zhang, Nicolas Papernot

Modern machine learning models are expensive to train, and there is a growing concern about the challenge of re
and show that for large language models (LLMs) we can efficiently exactly unlearn "fine-tuning data" (the data use
quantized k-means, which allows for effectively constant time unlearning operations. Our evaluation shows that th
operations.

Subjects: **Machine Learning (cs.LG)**; Artificial Intelligence (cs.AI); Cryptography and Security (cs.CR)
Cite as: arXiv:2402.00751 **[cs.LG]**
(or arXiv:2402.00751v2 **[cs.LG]** for this version)
https://doi.org/10.48550/arXiv.2402.00751

Submission history
From: Andrei Muresanu [view email]
[v1] Thu, 1 Feb 2024 16:43:04 UTC (266 KB)
[v2] Mon, 29 Sep 2025 20:10:01 UTC (460 KB)

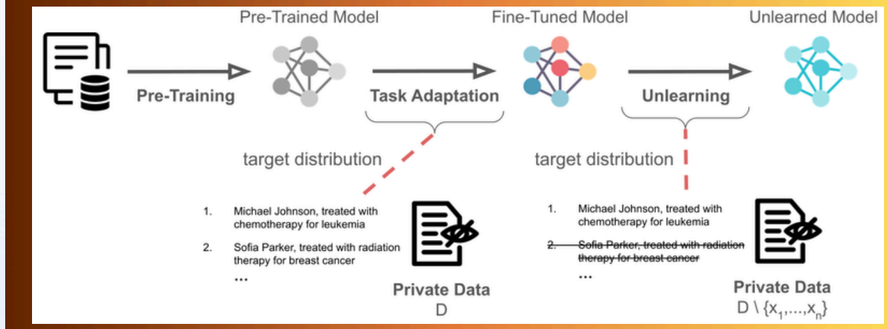

量化锚点去重思想启发

双层RAG检索流水线

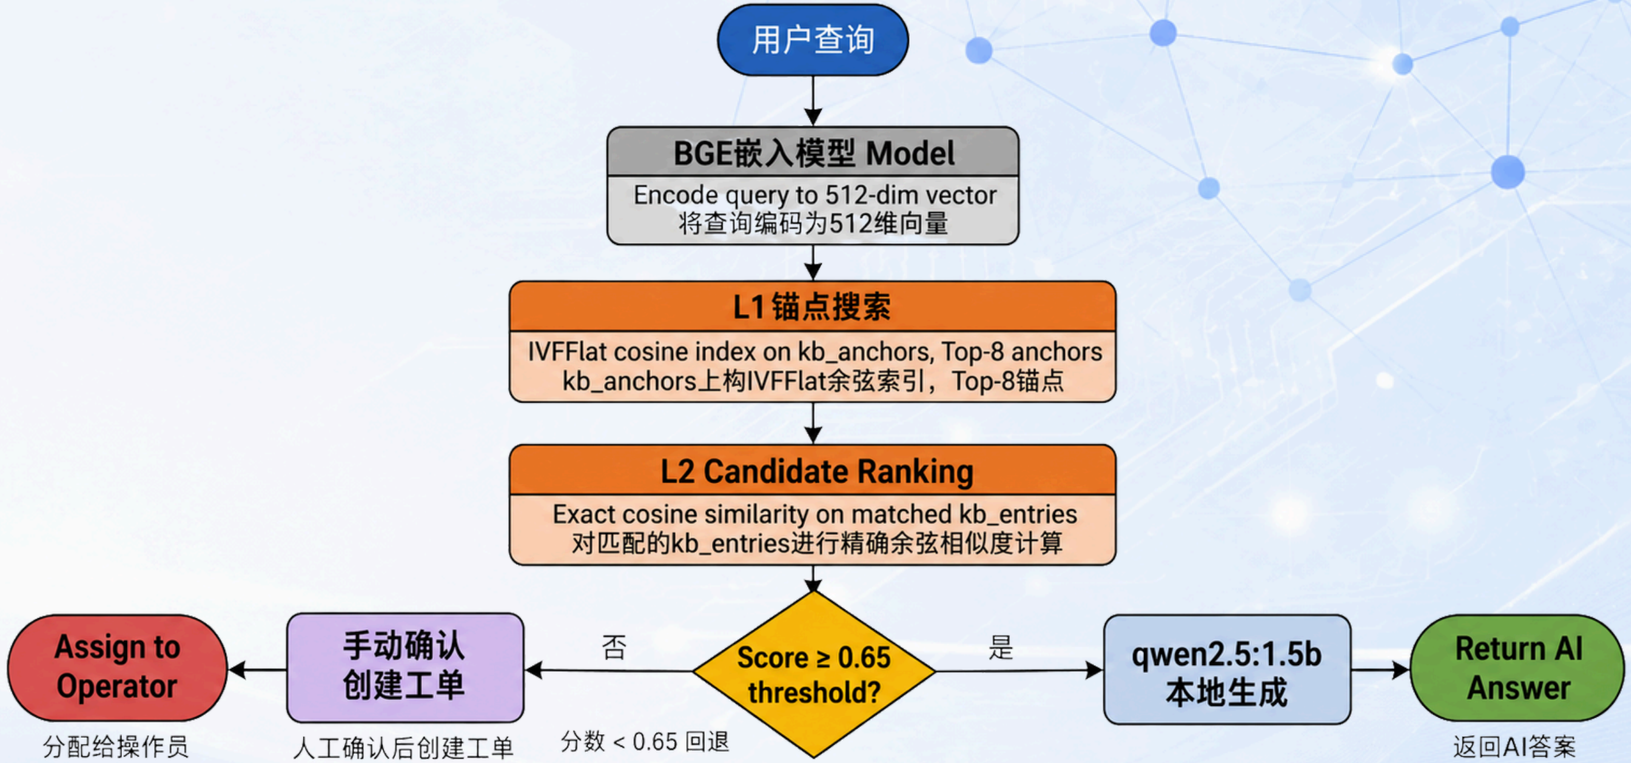

论文链接：Fast Exact Unlearning for In-Context Learning Data for LLMs

1 RAG核心：两阶段检索- GridTrace: Trace the path through the grid.

先粗筛、再精排

- **L1 · 粗筛路由 · kb_anchors量化锚点：**

  IVFFlat近似索引快速定位，取Top-8锚点，向量先量化压缩，相似条目共享同一锚点

- **L2 · 精排 · kb_entries全精度重排：**

  全精度余弦相似度精排，取Top-3，Score≥0.65，才算命中

贰·做了什么——RAG系统设计对比传统范式 Flat , IVF, HNSW

说不清

- 运维工单，系统要告诉用户『为什么是这个答案』。HNSW/IVF/Flat都只能给一个向量ID,只有GridTrace+能给出完整的 retrieval_trail--格命中→锚点展开→余弦精排全留痕。完整度 1.0 vs 其他5范式0.2.5倍独享。

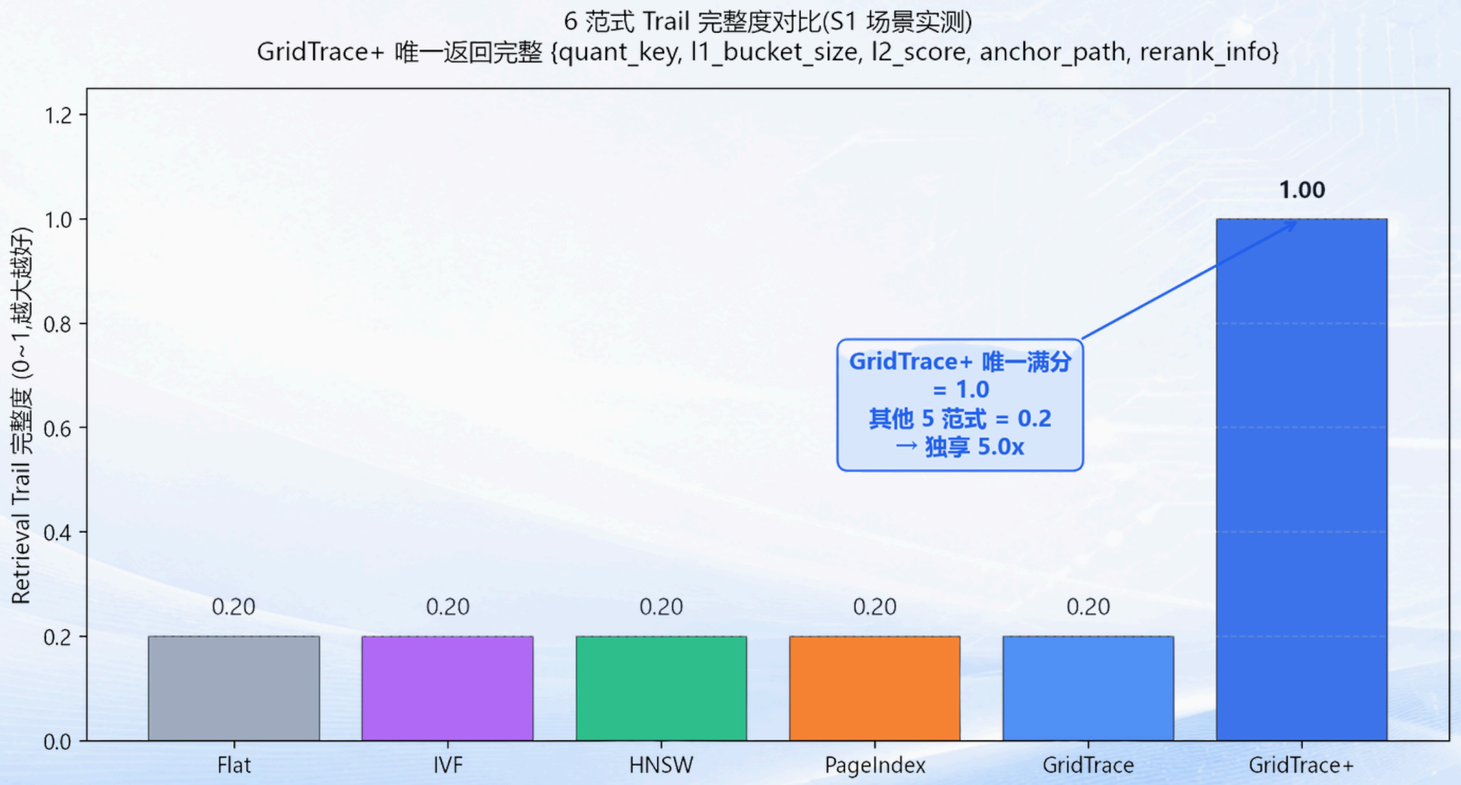

贰·做了什么——RAG系统设计对比传统范式 Flat , IVF, HNSW

删不掉

- 『被删数据物理消失』HNSW 的mark_deleted 是逻辑删除-节点还在内存里只是标了 flag,Index Size 0 释放。只有 GridTrace+是真物理删--mark_deleted=False 即可，实测释放 2.34 MB

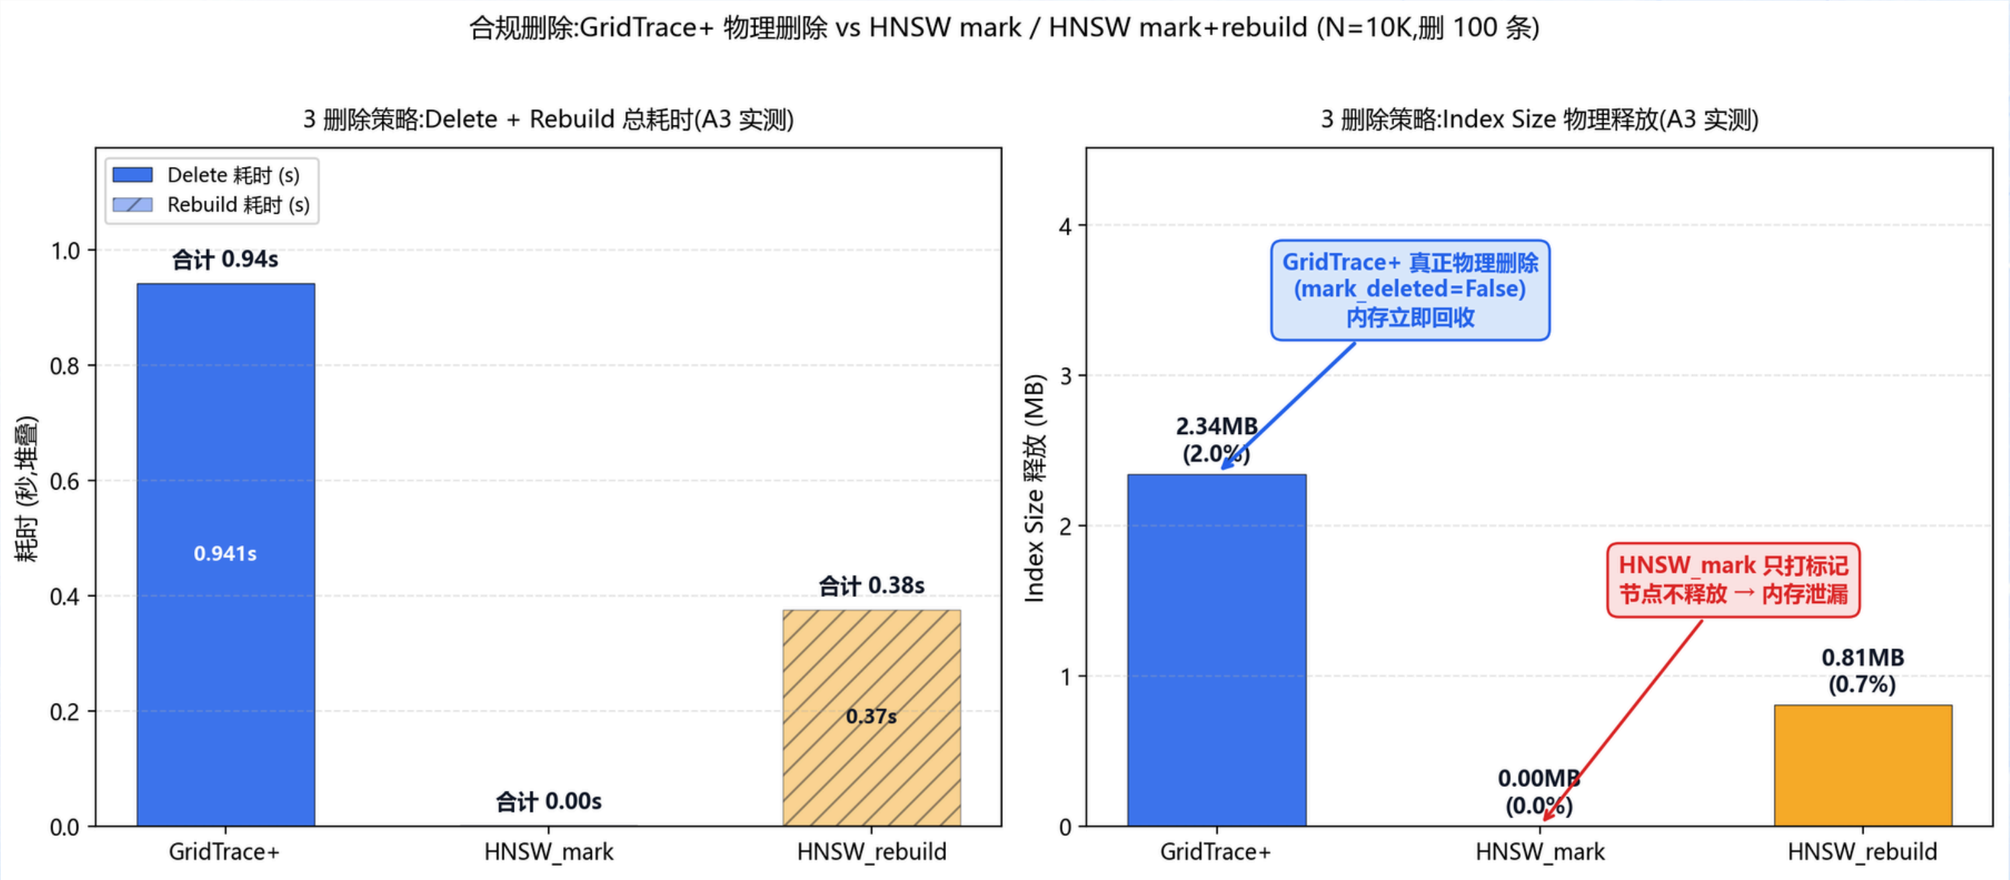

贰·做了什么——RAG系统设计对比传统范式 Flat , IVF, HNSW

训不动

- 运维KB 每天都在变：新告警、新 SOP、新runbook。IVF重训一次N=50K要93秒。GridTrace+同规模只要 5.7 秒,16 倍差

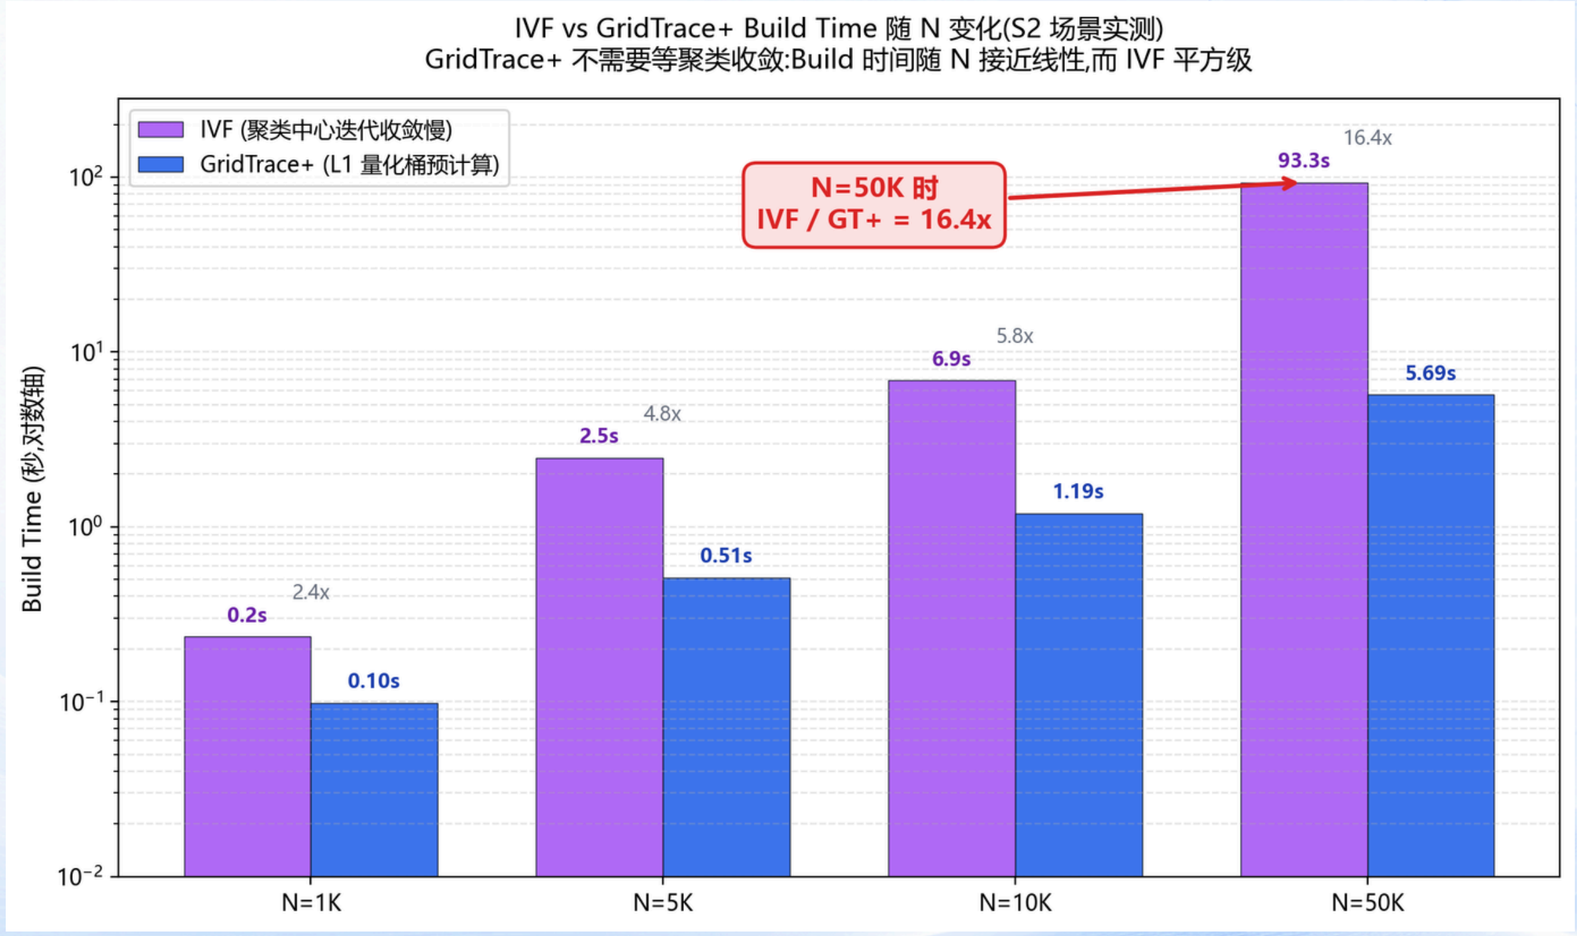

贰·做了什么——RAG系统设计对比前沿范式：PageIndex

South China University of Technology

PageIndex：无向量推理RAG

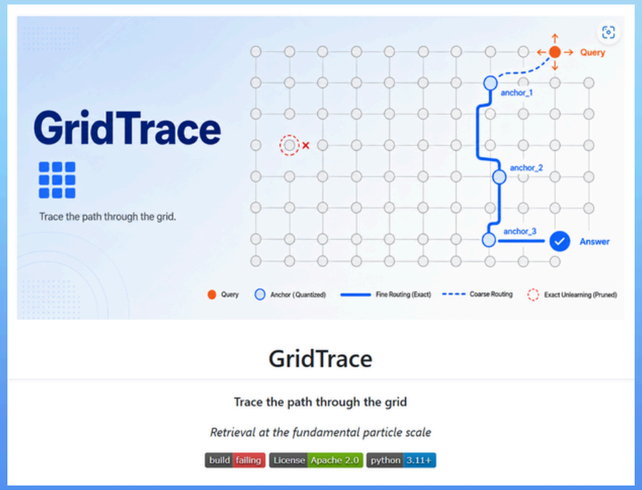

GridTrace
量化锚点层次检索

没有完美的RAG，只有最合适的RAG方案

对比维度	PageIndex	GridTrace
核心思想	基于文档树结构的推理检索	基于量化锚点的层次化向量检索
检索方式	Tree Search + LLM Reasoning	Anchor ANN + Entry Rerank
是否依赖Embedding	❌ 不需要	✅ 需要
是否依赖Vector DB	❌ 不需要	✅ 需要
索引结构	TOC Tree（目录树）	Grid → Anchor → Entry
查询流程	Query → Tree Traversal → Page	Query → Anchor → Entry → LLM
检索驱动力	推理（Reasoning）	相似度（Similarity）
检索延迟	较高	较低
Token消耗	高	极低
增量写入	一般	优秀
删除遗忘	一般	优秀
百万级扩展	一般	优秀
小模型友好	较差	优秀
典型场景	长文档分析	企业知识库

Github仓库链接：https://github.com/VectifyAI/PageIndex

Github仓库链接：https://github.com/guts-yang/GridTrace

1 RAG核心：两阶段检索-GridTrace: Trace the path through the grid.

实验调参

- 逐个参数调优

ε=0.02　L1-K=8

τ=0.65　Top-K=3

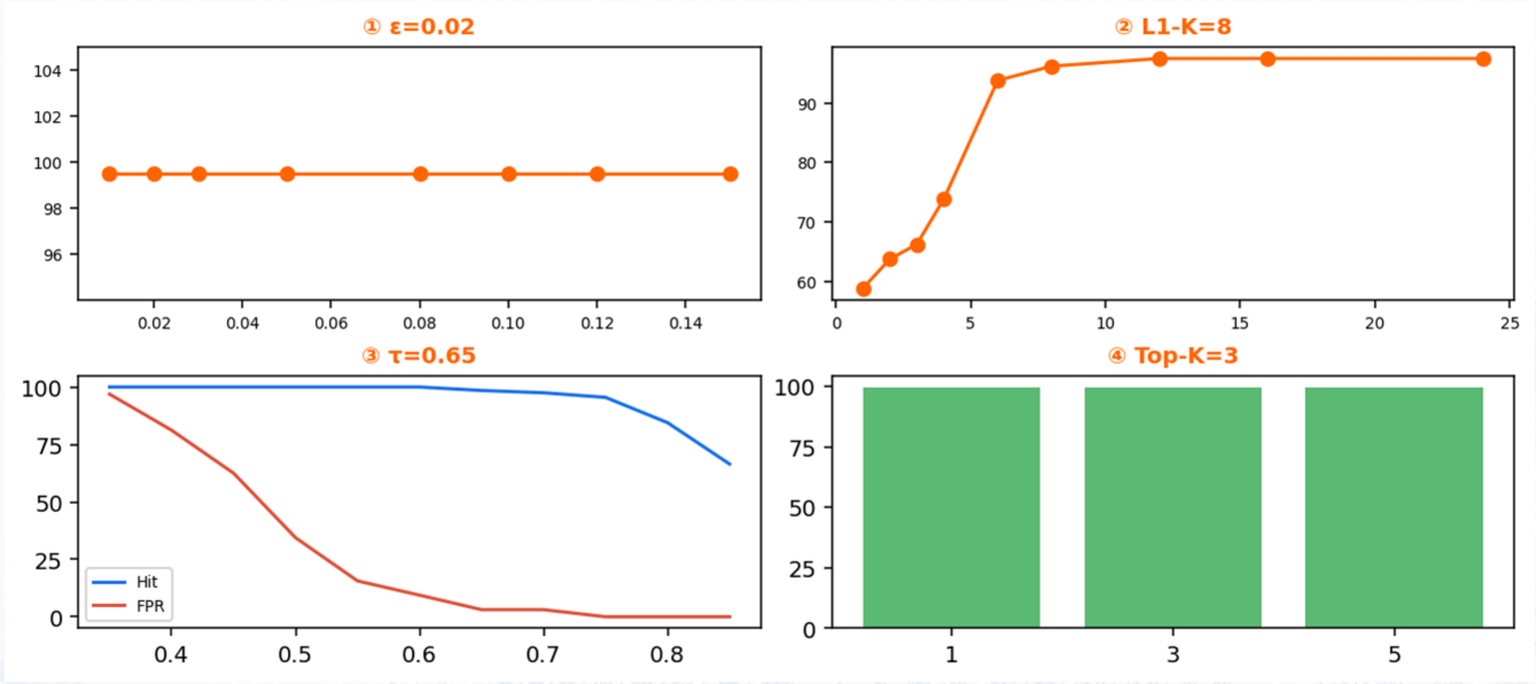

2 登录鉴权 + 角色跳转

鉴权机制 接口设计

1. 角色分为管理员、运维人员、员工
2. 员工仅支持AI对话与工单创建
3. 运维人员在员工的基础上支持仪表盘监控、工单管理与知识库管理
4. 管理员在运维人员的基础上支持账号管理

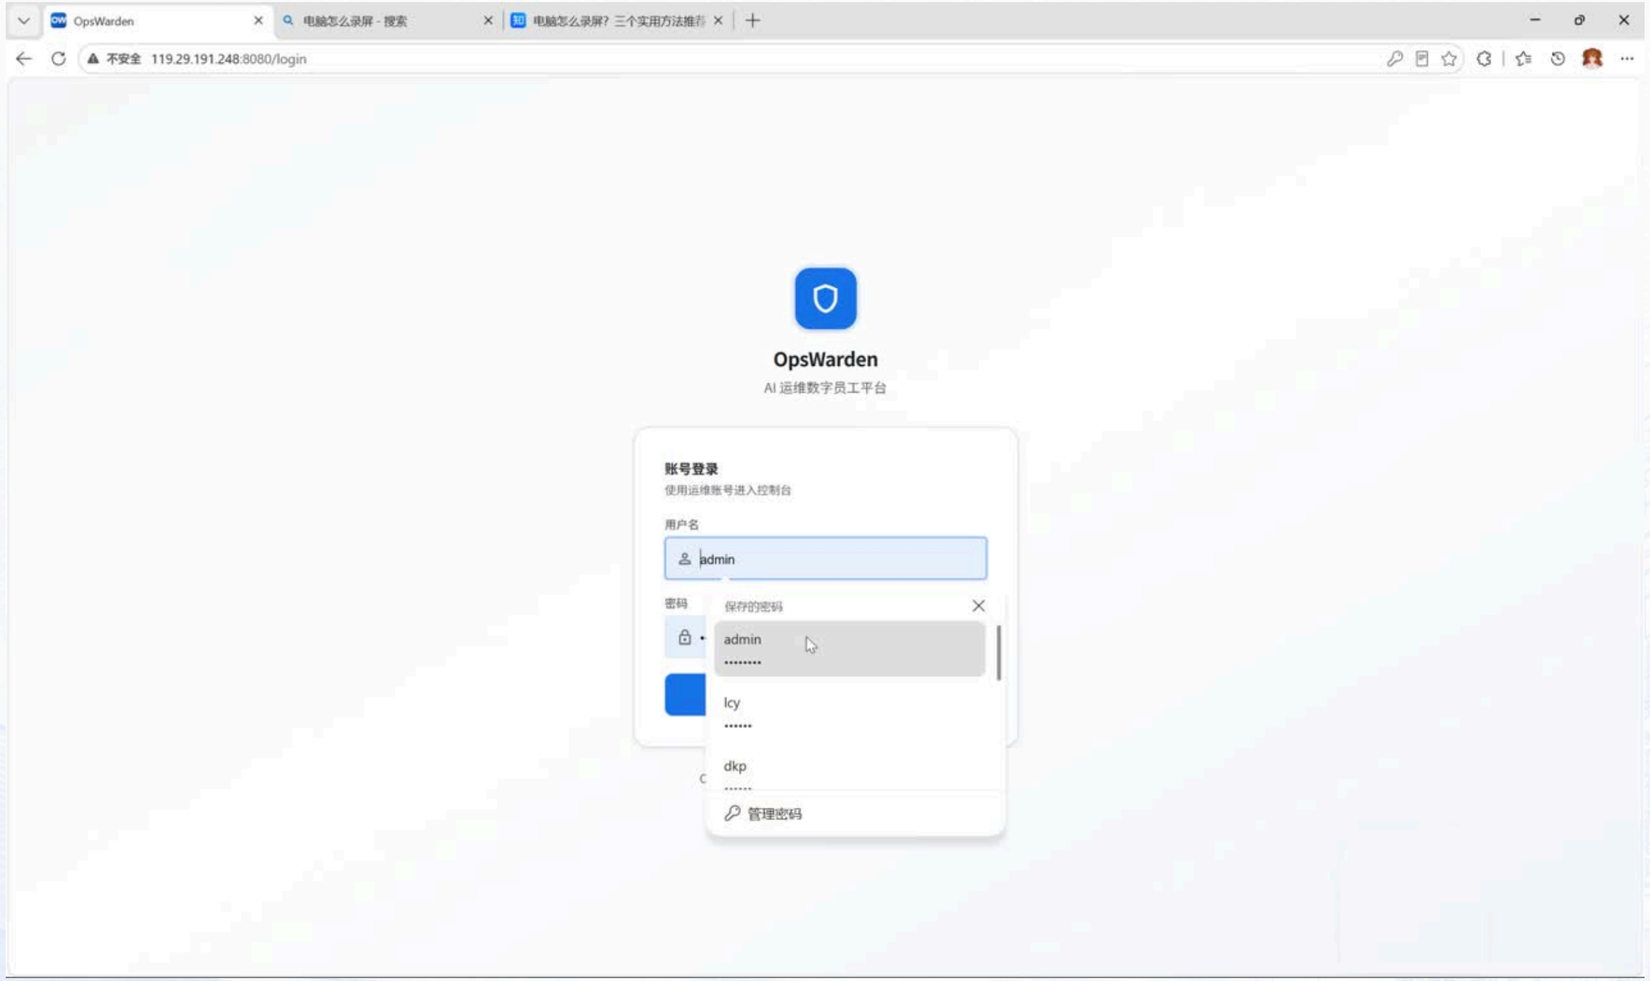

3 AI问答 命中知识库

命中知识库场景

1. 用户进行提问
2. RAG系统检索
3. 命中知识库
4. 毫秒级反应

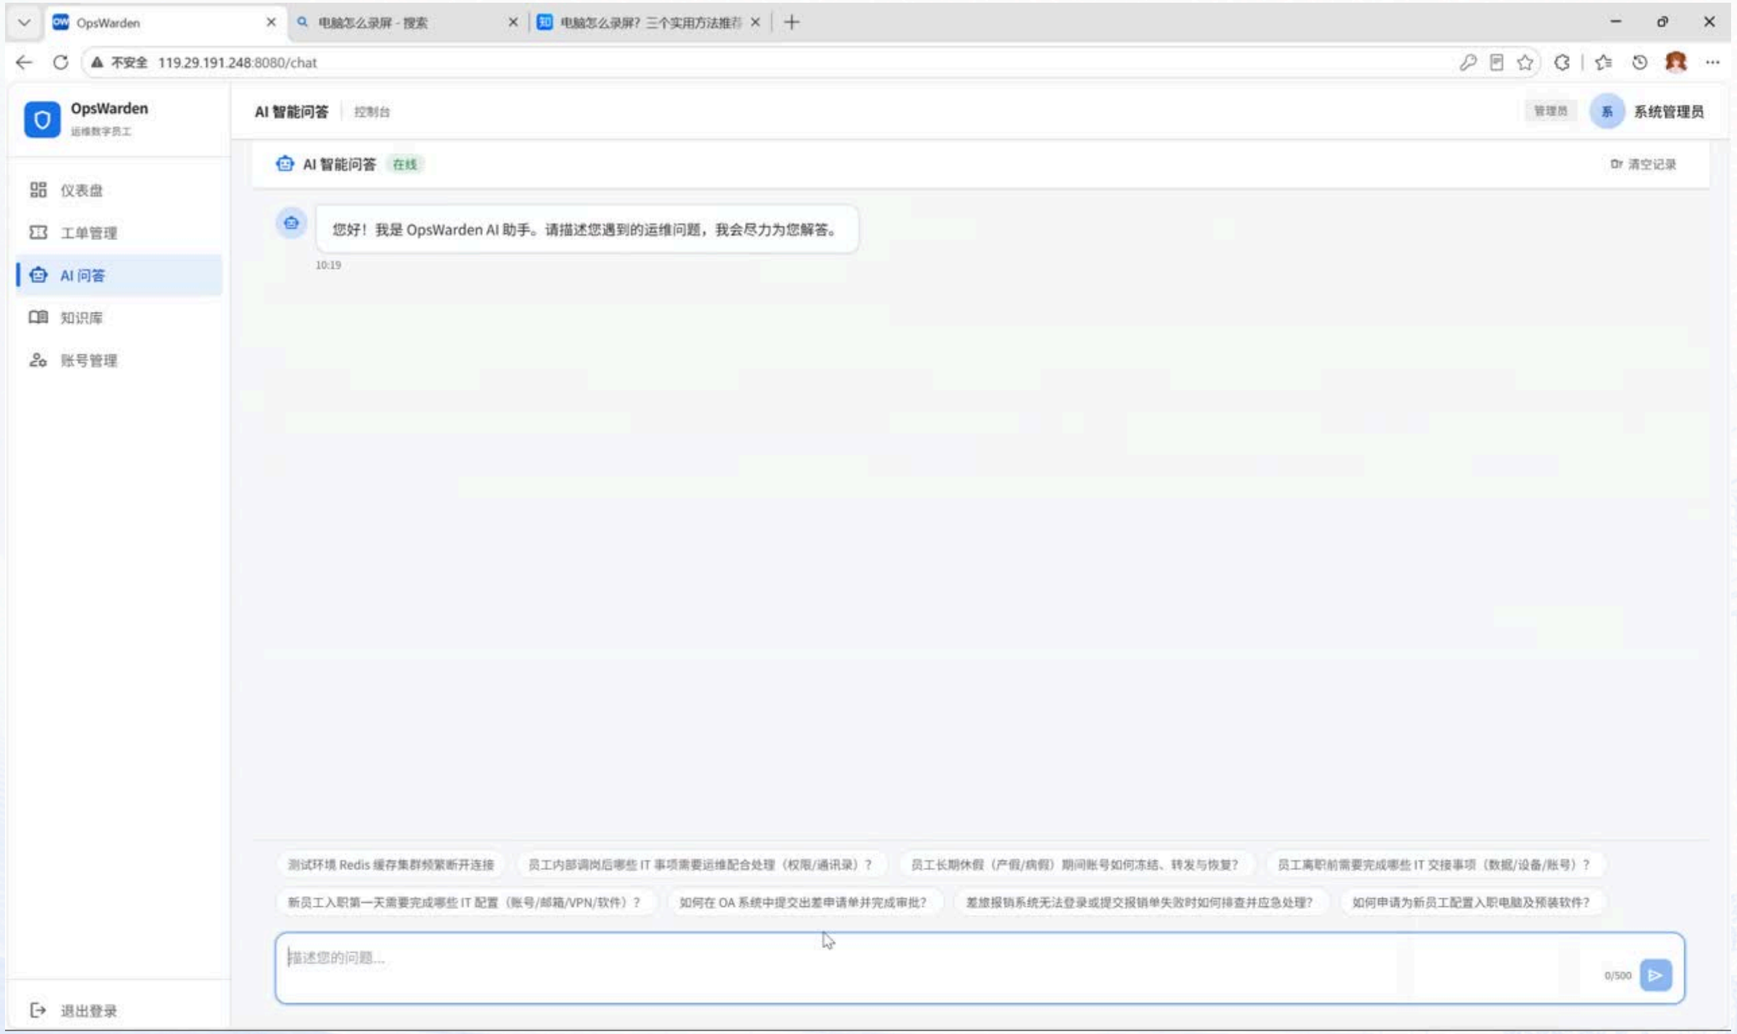

4 AI问答 未命中知识库

未命中知识库场景

1. 用户进行提问
2. RAG系统检索
3. 未命中知识库
4. 人工确认创建工单
5. 更新仪表盘

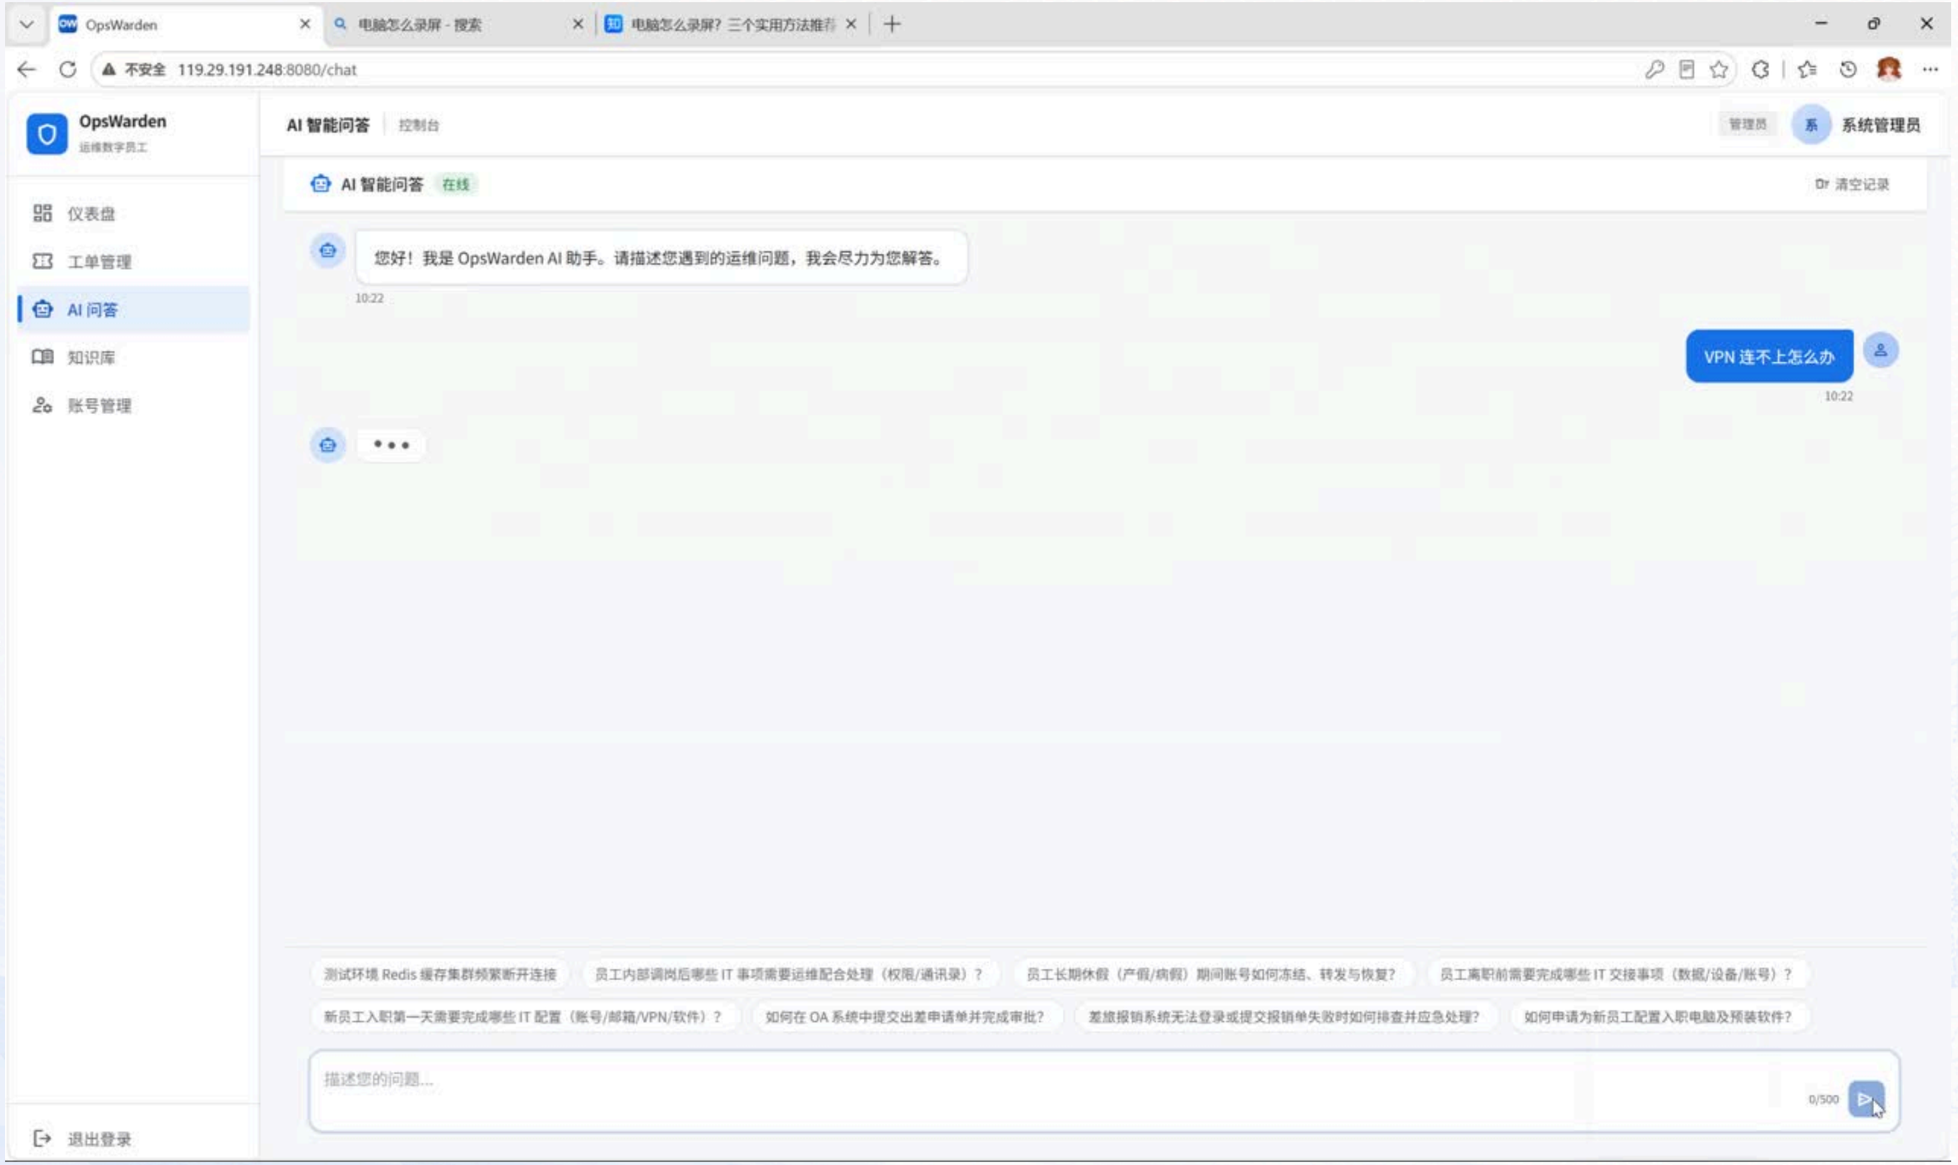

5 AI问答 写入知识库

写入知识库场景

1. 运维人员填写工单需求
2. 将Q-A对写入知识库
3. 计算Q-A对的向量空间锚点
4. 毫秒级计算

6 AI问答 知识回写-精准回答

业务闭环 · 知识回写后 AI 精准解答

1. 运维解决工单
2. 勾选「写入知识库」
3. 向量数据库实时更新
4. AI 检索命中并自动输出解决方案

7 工单管理

工单生命周期

1. 状态分为三类：
    a. 待处理
    b. 已解决
    c. 已关闭
2. 运维人员维护工单管理列表
3. 按照紧急程度划分
4. 可以手动创建工单

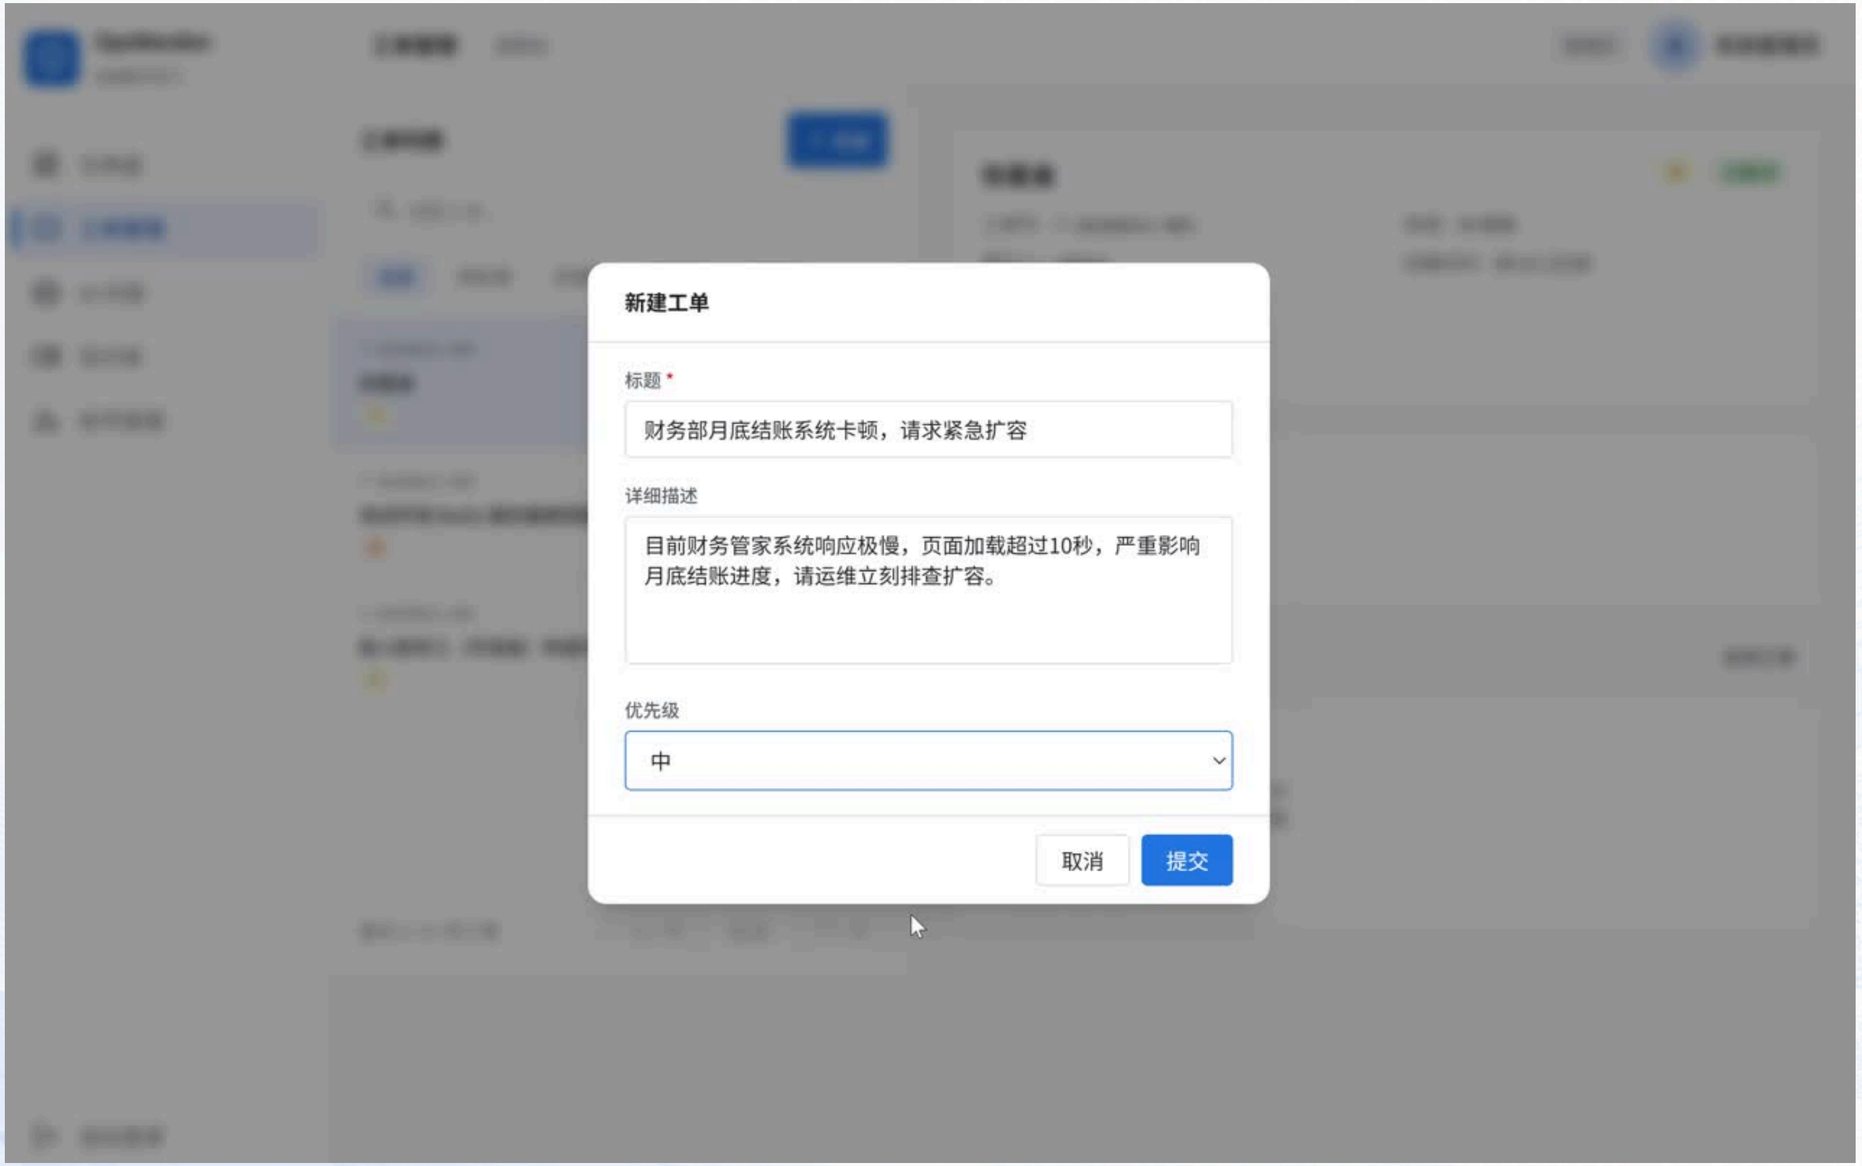

8 知识库管理

知识增删改查

1. 运维人员和管理员可以进行以下知识库操作
   a. 增加知识
   b. 删除知识
   c. 修改知识
   d. 查询知识

9 账号管理

冻结 / 删除账号

1. 管理员可以手动冻结账号
2. 避免权限滥用

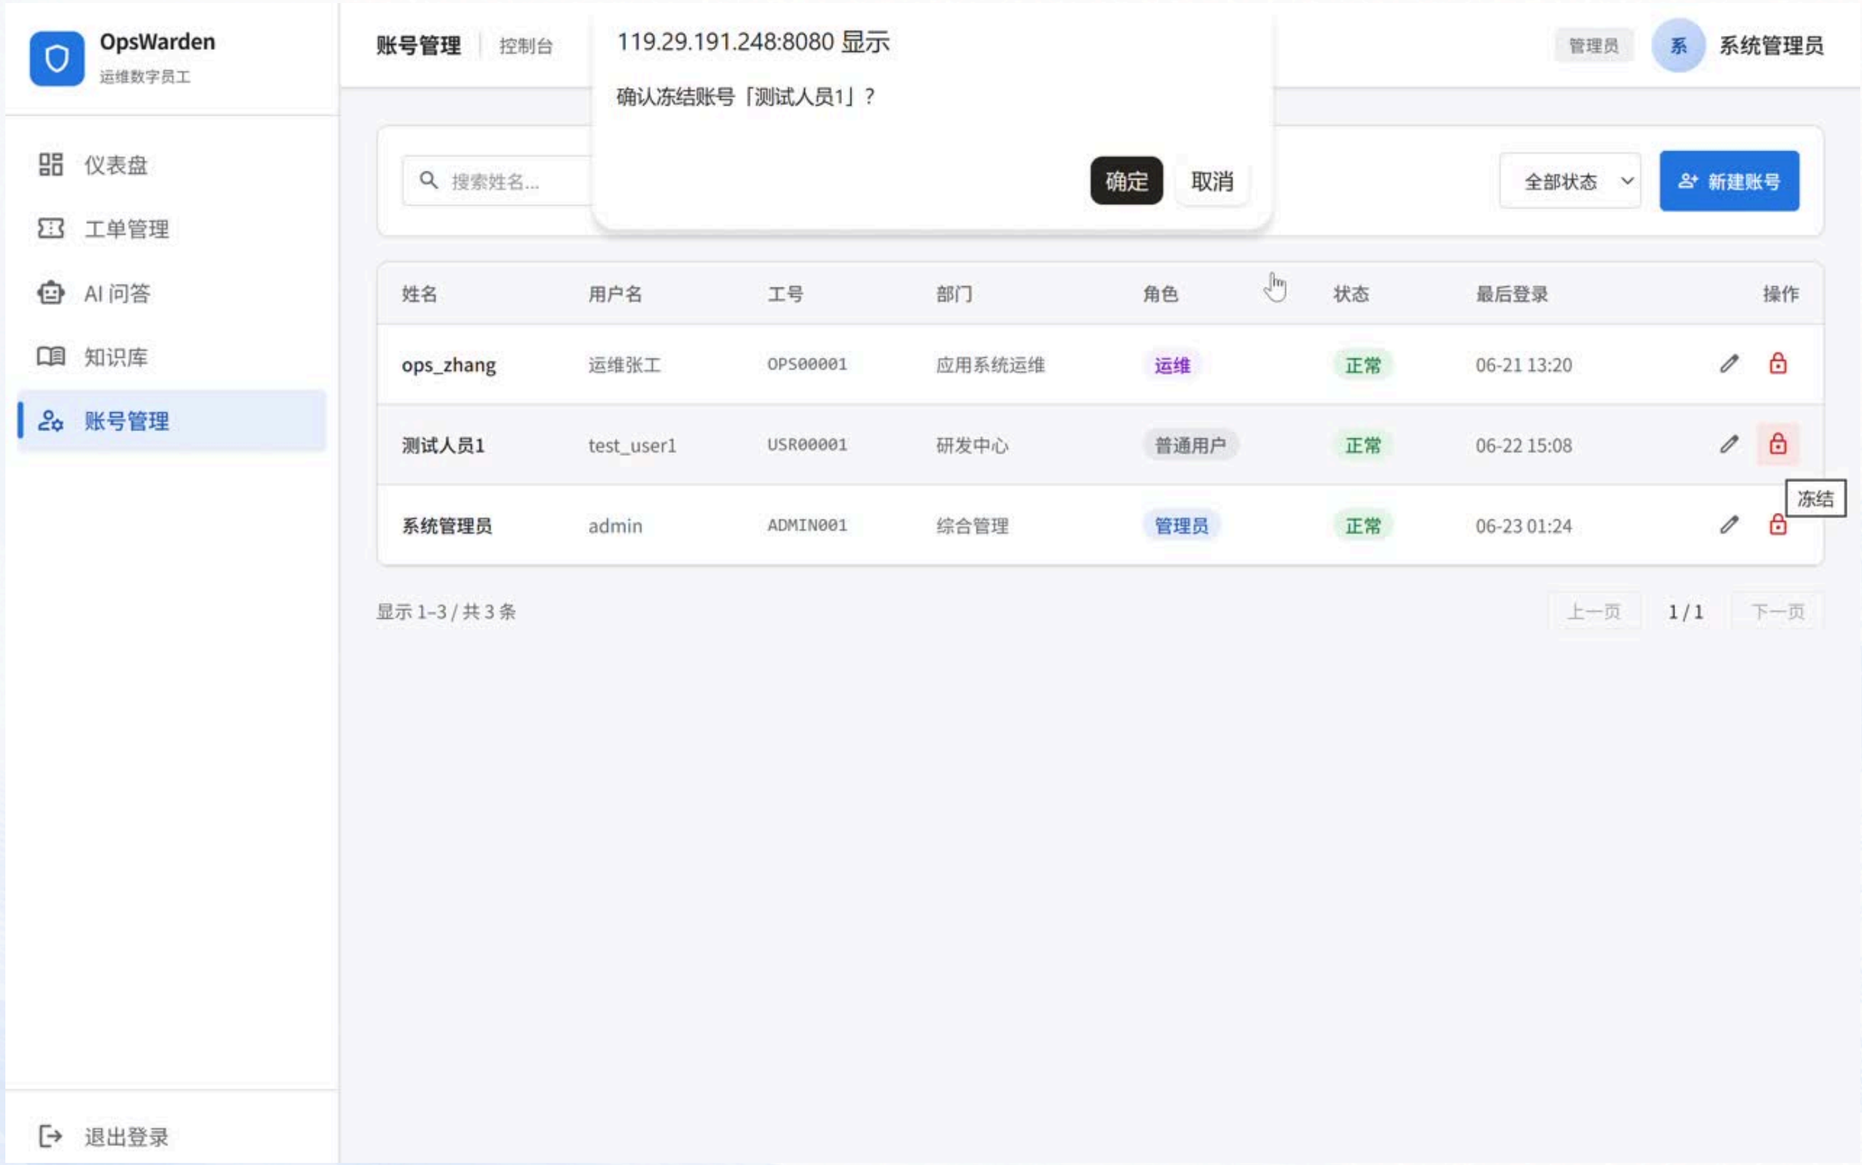

10 仪表盘

仪表盘状态监控

1. 管理员可以监控系统使用指标
2. 今日问答数量：用于推算系统负荷与成本
3. 待处理工单：未完成任务，监控进度
4. 账号总数：控制账号数量
5. 知识库条目：掌握知识库规模

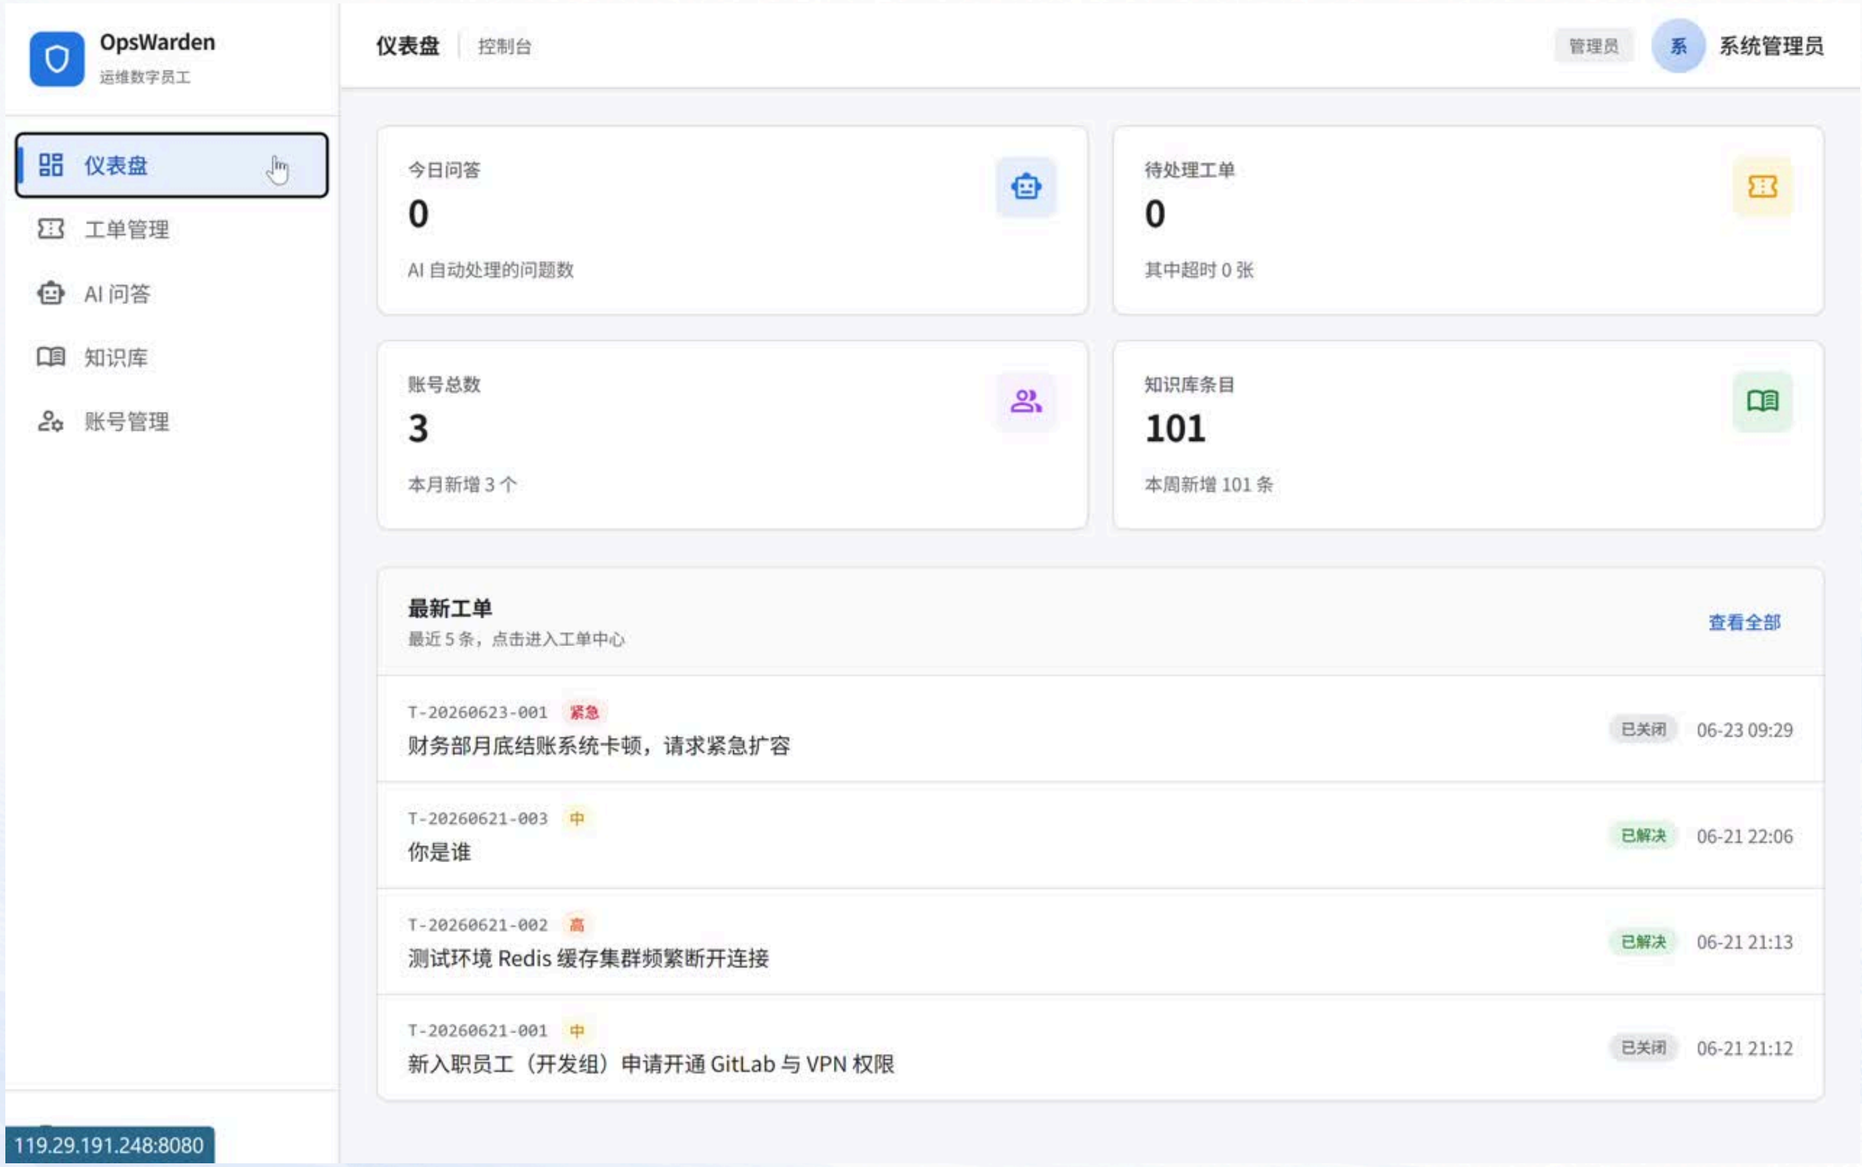

11 敏捷开发--Linear软件的使用

软件工程-敏捷开发场景

1. 在App上创建任务（issue），同时设定负责人、任务状态、任务截止时间、子任务等等
2. 支持同步Github仓库issue状态
3. 符合真实企业场景中团队协作敏捷开发场景

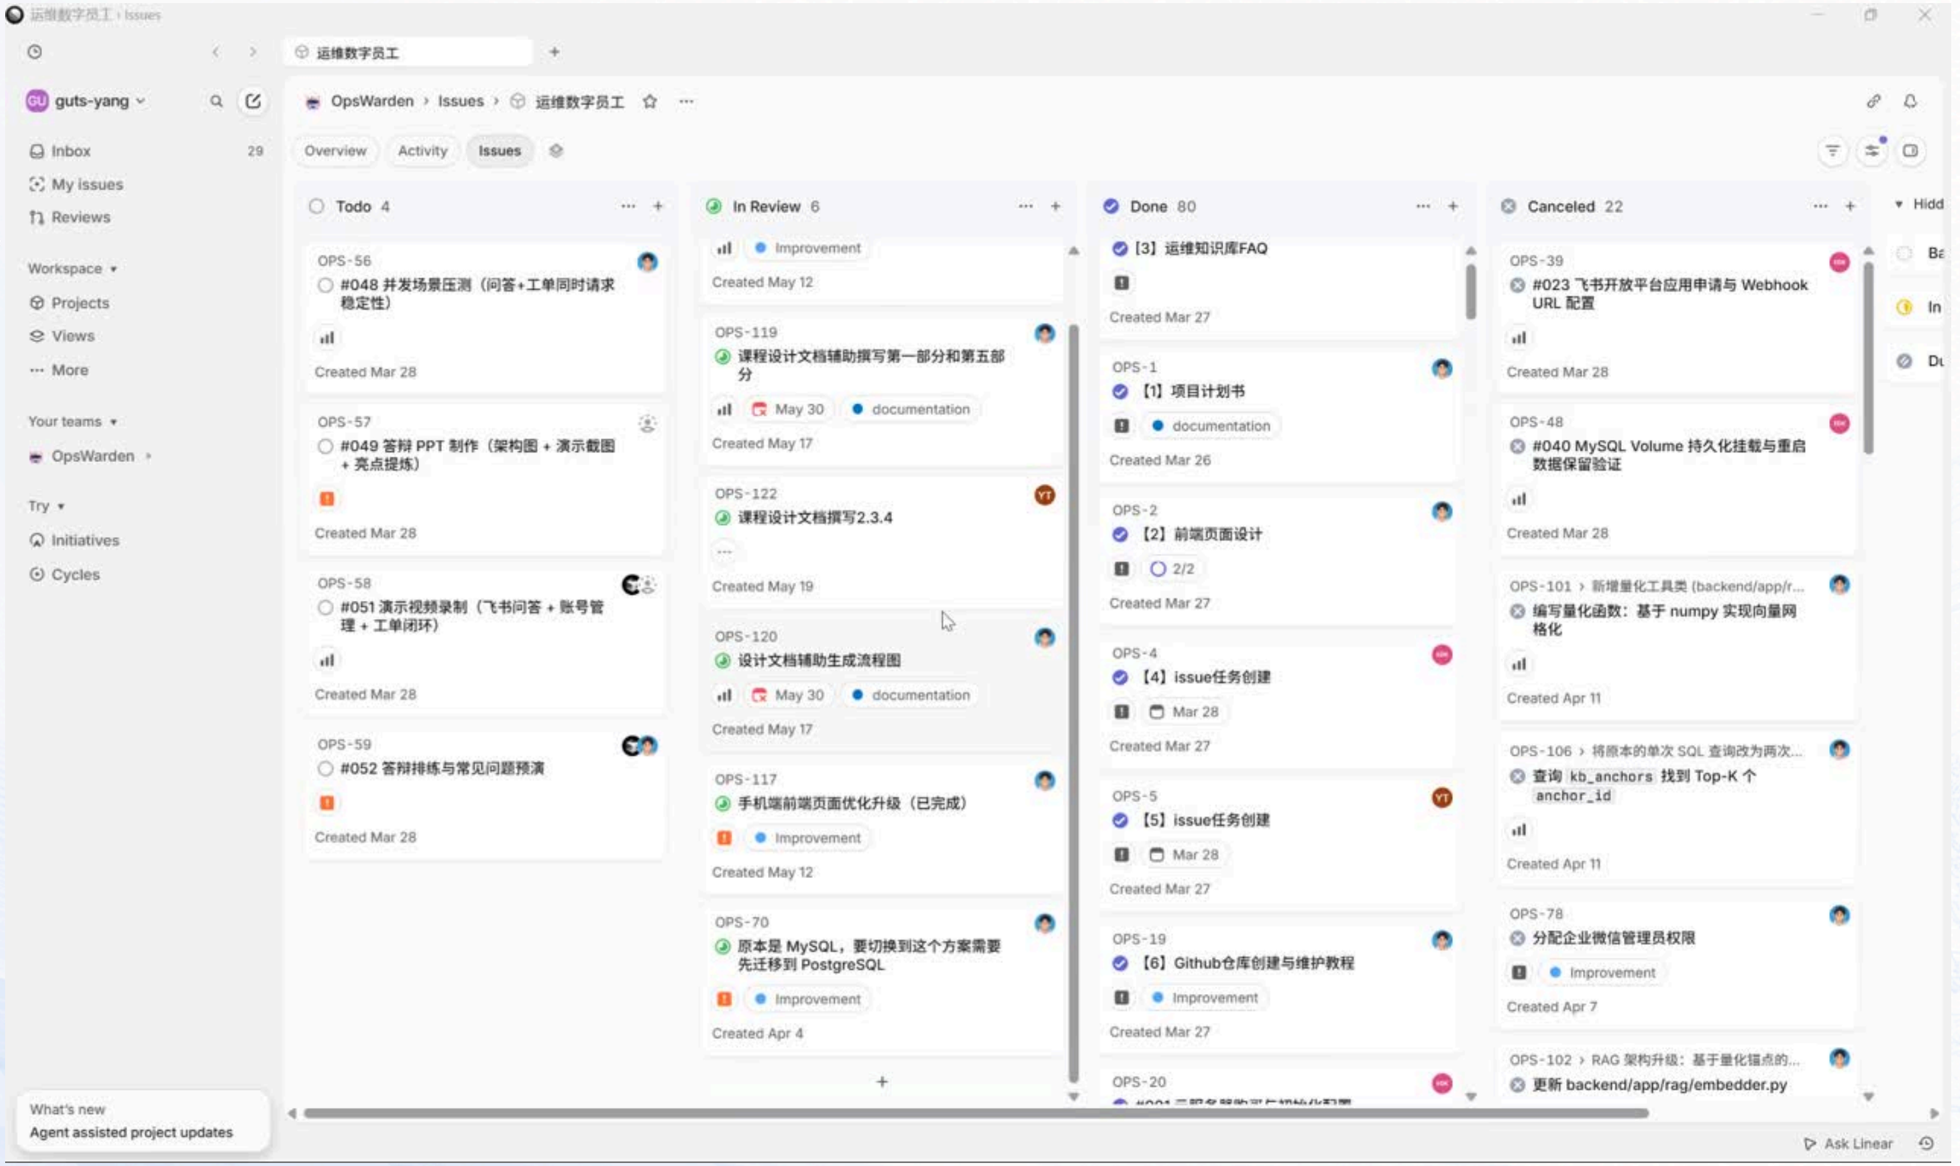

11 敏捷开发--Linear软件的使用

118	85	26	3
个 Issue 清晰任务拆分	个已完成 高效交付	个被取消 拥抱变化	人协作 责任明确

Linear 看板状态分布

1	2	4	85	26
待办	进行中	评审	已完成	已取消

用数据说话：Linear不只是工具，更是一种团队协作方式的升级

12 前端页面--移动端适配

PC端 + 移动端

双管齐下

同时支持PC端和移动端访问，前端组件设计周全

1. **前端不错位**
2. **管理员随时随地监控**
3. **员工随时随地使用**

我们做出的亮点

1. 两阶段检索：L1量化锚点粗筛（IVFFlat）+ L2全精度余弦精排，避免在大表上维护动态索引
2. 3种传统范式+1种新兴范式对比：解决3种传统范式的痛点，在多方面比新兴范式适配当前场景
3. 精确遗忘：每条知识带索引，可按文档精准删除（灵感来源：遗忘学习领域 ICML 2025论文）
4. Linear——软件工程敏捷开发的载体 + Cursor + Claude Code：使用前沿工具进行团队协作与辅助开发

又快又准

知识库更新不必重建索引

引用跨领域论文的Trick

前沿工具使用

会回答，会建单，会自主学习

才是真正的运维数字员工

谢谢各位老师

恳请批评指正

会回答、会建单、会自己学习，这才是真正的运维数字员工!

组长：廖晨扬

组员：吴雨彤、丁其彬

班级：2023级计算机科学与技术2班