

OpsWarden

运维数字员工 · 答辩资料合集

团队: 廖晨扬 · 吴雨彤 · 丁其彬

2023 级计算机科学与技术 2 班

本文档包含两部分:

第一部分: 10 分钟答辩讲稿 (贴 PDF 演示)

第二部分: 范式对比 + 超参调参 Q&A 弹药库 (30 问 + 速记卡)

第一部分 · 10 分钟答辩讲稿

OpsWarden · 答辩讲稿(基于 PDF 演示稿, 10 分钟)

配套演示:presentation/运维数字员工.pdf (27 页, 42 MB)
风格:雷军式短句、停顿、对比爆点、口号收尾。
总时长 10:00 (贴 10 分钟红线, 无冗余)。

一、10 分钟时间轴(总览)

开场	P1 封面	0:30	0:30	一句口号"会回答、会建单、会学
壹·为什么做	P2-3	1:20	1:50	痛点三连 + 对标小Q/飞飞助手
团队分工	P4	0:40	2:30	AI / 后端 / 部署三足鼎立
请求流全景	P5	0:25	2:55	一图带过, 过场
RAG 核心:GridTrace	P6-7	1:30	4:25	论文启发 + L1锚点粗筛 + L2精排
vs 传统 3 范式	P8-10	1:30	5:55	说不清 / 删不掉 / 训不动 三大痛点
vs PageIndex	P11	0:40	6:35	11 项对比 + "没有完美的 RAG"
实验调参	P12	0:30	7:05	四组超参, $\epsilon=0.02$ / $L1-K=8$ / τ
系统功能 9 场景	P13-21	1:30	8:35	登录 / 命中 / 未命中 / 写入 /
敏捷开发	P22-23	0:30	9:05	Linear 同步 GitHub, 数据说话
移动端	P24	0:15	9:20	PC + 移动端双管齐下
叁·亮点	P25	0:30	9:50	四句话四点亮点
收尾	P26-27	0:10	10:00	"三会"口号 + 致谢

重点段:RAG 核心 + 范式对比合计 4:00, 占全程 40%。
控场提醒:每段时长大致按 0:30 / 1:20 / 1:30 / 1:30 / 0:40 / 0:30 / 1:30 / 0:30 / 0:15 / 0:30 / 0:10 配, 实际演讲时按现场气氛 ± 5 秒。

二、逐页口播讲稿

P1 ·

各位老师好!
今天我带来的课题是——运维数字员工 OpsWarden。
团队:廖晨扬, 负责 AI 架构和 RAG;吴雨彤, 负责后端和数据库;丁其彬, 负责部署和云服务。
2023 级计算机科学与技术 2 班。
我们的数字员工, 会回答、会建单、会自己学习——后面我会用 10 分钟, 把这三件事讲清楚。

P2-3 · 壹·为什么做(1:20)

为什么做？三个字：慢、贵、散。

慢——企业运维同学每天在重复回答同样的问题，人工响应慢，员工排队等。

贵——大量重复咨询，人工成本高，一个运维同学一年人力成本二三十万。

散——知识分散在聊天记录里，难复用。今天解决的问题，明天换个人又得重来。

怎么破？

我们对标业界已经验证的方案——腾讯的“小Q同学”、讯飞的“飞飞助手”——它们都基于同一套核心技术：RAG，检索增强生成。

我们做的，就是把 RAG 落到运维场景，把内部运维知识统一管起来，让一个数字员工 7×24 顶一个真员工。

P4 · 团队分工(0:40)

三人团队，各司其职。

廖晨扬，做的是大脑——AI 架构设计、RAG 设计、前端设计、敏捷开发统筹。

吴雨彤，做的是骨架——后端接口、账号登录、工单模块、数据库设计。

丁其彬，做的是四肢——Docker 容器化、云服务器部署、部署本地大模型、申请域名。

AI、后端、部署，全链路我们自己搞定。

接下来看一条请求怎么流。

P5 · 请求流全景(0:25)

一句话带过：用户在 Web 端提问 → FastAPI 接鉴权 → 路由进 RAG 引擎 → 命中就直接生成回答；没命中，自动开工单 → 运维处理后，可以选择写回知识库 → 下次同款问题，AI 自己答。

核心在 RAG。请翻到第 6 页，这是 OpsWarden 的灵魂。

P6-7 · RAG 核心:GridTrace(1:30)*全场最重

我们的 RAG，名字叫 GridTrace——Trace the path through the grid，在网格中追踪路径。

思想不是凭空来的。我们读了 ICML 2025 一篇论文——Fast Exact Unlearning for In-Context Learning Data for LLMs——把它的精确遗忘思想反过来用，变成了精确去重。

具体怎么干？两阶段检索。

L1 粗筛路由——向量先量化压缩，相近的向量共享同一个量化锚点。用 IVFFlat 近似索引，一次定位到 Top-8 个锚点桶。这一步把搜索范围从十万级砍到个位数。

L2 精排——只在这 8 个桶里，做全精度余弦相似度，取最像的 Top-3。分数必须 ≥ 0.65 ，才算命中。

先粗筛、再精排——这就是又快又准的秘密。

命中交给大模型生成；没命中，直接进工单。

P8-10 · vs 传统 3 范式(1:30)*三大独享

GridTrace 是不是自嗨？我们跑了 1800 组实验，拿它和 3 种传统范式——Flat、IVF、HNSW——硬刚。

三大独享优势，运维场景刚需。

第一，说得清。运维工单，系统必须告诉用户“为什么是这个答案”。HNSW、IVF、Flat 只能给一个向量 ID，只有 GridTrace+ 能给出完整 retrieval_trail——网格命中 → 锚点展开 → 余弦精排，5 步全留痕。完整度 1.0 vs 其他 0.2, 5 倍独享。

第二，删得掉。GDPR、数据安全法要求“被删数据物理消失”。HNSW 的 mark_deleted 是逻辑删除——节点还在内存，只是标了 flag, Index Size 0 释放。只有 GridTrace+ 是真物理删——实测释放 2.34 MB。

第三，训得动。运维 KB 每天都在变：新告警、新 SOP、新 runbook。IVF 重训一次 N=50K 要 93

秒——运维同学等不起。GridTrace+ 同规模只要 5.7 秒, 16 倍差距。
数字是死的, 场景是真的。这就是 GridTrace 在运维场景的独门武器。

P11 · vs PageIndex (0:40)

还有一种前沿范式叫 PageIndex——无向量推理 RAG, 基于文档树结构, LLM 推理检索。

我们做了 11 项对比: 核心思想、检索方式、Embedding 依赖、索引结构、查询流程、检索驱动力、检索延迟、Token 消耗、增量写入、删除遗忘、百万级扩展、小模型友好。

PageIndex 强在长文档分析, 但检索延迟高、Token 消耗大、增量写入一般、删除遗忘一般。

GridTrace 在延迟、Token、增量、删除、扩展性这五项上全部胜出。

没有完美的 RAG, 只有最合适的 RAG 方案。运维场景要的是又快又轻又要能增删, GridTrace 是最合适的。

P12 · 实验调参 (0:30)

RAG 好不好, 看超参配得对不对。

我们的 4 个核心超参: ϵ 量化步长 = 0.02、L1-K 锚点候选数 = 8、 τ 分数阈值 = 0.65、Top-K 返回数 = 3。

这 4 个数, 不是拍脑袋的。是 1800 组网格实验验证出来的帕累托最优——后面答辩老师感兴趣, 可以展开讲。

总之: 一行配置, 一组数据。

P13-21 · 系统功能 9 场景 (1:30)*产品力展示

接下来 1 分半, 过一遍系统的 9 个核心场景, 每个都有真实功能。

1, 登录鉴权——三种角色: 管理员、运维人员、员工。员工只能 AI 问答 + 建工单; 运维再加仪表盘、工单管理、知识库管理; 管理员再加账号管理。

2, AI 问答 · 命中——用户提问 → RAG 检索 → 命中知识库 → 毫秒级返回。

3, AI 问答 · 未命中——用户提问 → RAG 检索 → 未命中 → 人工确认 → 自动建工单 → 仪表盘更新。答不上来不会硬答。

4, AI 问答 · 写入知识库——运维填工单需求 → 系统把 Q-A 对写入知识库 → 自动计算向量空间锚点 → 毫秒级完成。

5, AI 问答 · 知识回写——运维解决工单 → 勾选“写入知识库” → 向量数据库实时更新 → 下次同款问题, AI 自己答。这就是会自己学习。

6, 工单管理——三状态: 待处理 / 已解决 / 已关闭。按紧急程度划分, 支持手动建单。

7, 知识库管理——增、删、改、查 全开放, 运维人员即可操作。

8, 账号管理——管理员冻结 / 删除账号, 避免权限滥用。

9, 仪表盘——今日问答数、待处理工单、账号总数、知识库条目, 系统状态一眼掌握。

P22-23 · 敏捷开发: Linear (0:30)

软件工程这一块, 我们用的是 Linear。

在 App 上建 issue, 设负责人、状态、截止时间、子任务——和真实企业一样。

Linear 同步 GitHub 仓库 issue 状态, 真正符合企业团队协作的敏捷开发场景。

我们的项目从需求到上线, 全程在 Linear 上跑——这不是一个工具, 是一种团队协作方式的升级。

P24 · 移动端适配 (0:15)

前端同时支持 PC 端和移动端。

管理员随时随地监控, 员工随时随地使用。

组件设计周全, 不错位、不卡顿。

P25 · 叁 · 亮点 (0:30)

- 一句话总结我们做出来的四大亮点。
- 一, 两阶段检索——L1 量化锚点粗筛 + L2 全精度余弦精排, 又快又准, 知识库更新不必重建索引。
 - 二, 3 传统范式 + 1 新兴范式对比——解决 3 传统范式的痛点, 在多方面比新兴范式更适配运维场景。
 - 三, 精确遗忘——每条知识带索引, 可按文档精准删除, 灵感来自 ICML 2025 论文。
 - 四, Linear + Cursor + Claude Code——使用前沿工具进行团队协作与辅助开发。

P26-27 · 收尾 (0:10)

回到开头那句话。

会回答、会建单、会自己学习——这才是真正的运维数字员工。

我们的方案: OpsWarden。

以上就是我的全部汇报, 谢谢各位老师, 恳请批评指正!

三、控场 & 应急清单

老师追问"1800 组实验"	翻回 P12, 引向 docs/hyperparam_charts/ 四张图, 讲 τ 甜蜜点 + L1-K
老师追问"GridTrace 论文"	ICML 2025, Fast Exact Unlearning for In-Context Learning Data
老师追问"PageIndex 仓库"	https://github.com/VectifyAI/PageIndex , GridTrace 仓库 https://github.com/VectifyAI/GridTrace
老师追问"性能数据"	Hit@1 paraphrase 98.5%、FPR 3.1%、L1-K=8 召回 95%、IVF build 93s
时间超 9:30	P13-21 9 场景加速到每项 8-10s, P25 亮点压到 1 句话
时间不够	砍 P22-23 Linear 段、P24 移动端, P25 亮点合并到 P26 收尾

四、关键数据口袋卡 (贴在讲稿旁, 随用随取)

1800 组	V2 1584 + V3 216 网络实验
$\tau = 0.65$	FPR 81.2% $\rightarrow$ 3.1%, 甜蜜点
L1-K = 8	召回 0.575 $\rightarrow$ 0.95, 边际收益拐点
$\epsilon = 0.02$	量化步长, 平台区内
Top-K = 3	精排返回数
5.7s vs 93s	GT+ build vs IVF build @ N=50K, 16.4x
2.34 MB	GT+ 物理删除释放内存
1.0 vs 0.2	retrieval_trail 完整度, 5x 独享
3 角色	管理员 / 运维 / 员工
3 工单状态	待处理 / 已解决 / 已关闭
9 场景	P13-21 系统功能完整闭环

3+1 范式	Flat / IVF / HNSW + PageIndex
ICML 2025	论文 Fast Exact Unlearning for In-Context Learning Data for LL
DeepSeek	温度 0.1, 无 Key 兜底
BGE-small-zh	512 维中文向量模型

五、雷区提醒(说错就翻车)

"我们是 RAG"	"我们是 运维场景的 RAG, 卡位运维三个具体痛点"
"我们比 HNSW 更快"	"HNSW 速度综合最优, 我们不抢赛道"
"我们 Hit@1 更高"	"S1/S2/S3 HNSW 第一, 我们S5 trail 完整度 5x 独享"
"零重建"	"物理删除 + 5.7s 重建量化, 敢常更新"
"替代 HNSW"	"卡位运维:敢重训、能合规、可解释"
"用 RAG 做知识库"	"用 GridTrace 两阶段检索做运维知识库"
"Linear 是工具"	"Linear 是团队协作方式的升级"

第二部分 · 范式对比 + 超参调参 Q&A 弹药库

答辩 Q&A 弹药库 · 范式对比 + 超参调参

配套讲稿:presentation/答辩讲稿_10min_基于PDF.md

配套报告:docs/PARADIGM_BENCHMARK_V2_REPORT.md / PARADIGM_BENCHMARK_V3_A3_REPORT.md / rag_hyperparam_report_v3_joint.md

配套图:docs/paradigm_benchmark_v2_charts/(8 张) / docs/hyperparam_charts/(4 张) / docs/rag4_charts/(3 张)

风格:老师问什么就抽哪条,短句 + 数字 + 引用图。

A 篇 · 传统范式对比试验(10 问)

答(20s):

按"覆盖度"原则,横向打 4 类技术路线各一代表:

- Flat = 暴力基线(上界)
- IVF = 工业标准(中 N 主流)
- HNSW = 当前 SOTA(图方法)
- PageIndex = 2024 新兴(无向量 RAG / 树)

不选 BGE-M3 / CoBERT:它们是模型不是索引范式——比的是"路",不是"车"。

不选 Pinecone / Weaviate:商业产品黑盒。

金句:"我们比的是'路',不是'车'。"

A2. GridTrace / GridTrace+ / 4 个基线 怎么分工?

答(15s):

- GridTrace:开源论文版(github.com/guts-yang/GridTrace);
- GridTrace+:在开源版上 + RAG 自学习闭环 + hit_trail 字段 + A3 物理删除优化(本项目落地版);
- 4 个基线 = Flat / IVF / HNSW / PageIndex。

GT+ 在 S1/S2/S3 Hit@1 不抢 HNSW 第一,但在 S5 trail 完整度 5x 独享。

A3. 实验数据集多大?跑了多少次?怎么保证公平?

答(20s):

- KB 规模:1K / 10K / 50K / 100K 四档(expand_kb_v3 脚本);
- Query 集:332 paraphrase + 80 hard_confusion = 412 条;
- 每组配置:--repeats 3 取均值,消除抖动;
- 固定 seed=42,6 范式一视同仁;
- 统一指标:Hit@1 paraphrase / exact / hard / FPR / L1_recall / 延迟 p50 / 索引大小 / build 时间。

金句: "同一个 query, 6 范式轮着跑, 谁也别想偷跑。"

A4. Hit@1 / FPR / L1_recall 怎么定义?为什么不用 Recall@K / NDCG / MRR?

- 答 (20s):
- Hit@1 paraphrase: 同义改写提问, 看 Top-1 是不是命中"意思相同的答案"——语义鲁棒性;
 - Hit@1 exact: 字面匹配——精确度上界;
 - Hit@1 hard_confusion: 近义易混——歧义消解;
 - FPR: 无关 query 被判为命中——胡言乱语率;
 - L1_recall: L1 锚点桶覆盖到正确答案——粗筛质量。

不选 NDCG / MRR: 运维只关心"答没答对", 不关心"排第几"——Hit@1 更直接。

金句: "运维要'对', 不要'还行'。"

A5. *GT+ 在 S1/S2/S3 不如 HNSW, 为什么还用?是不是自嗨?

- 答 (25s, 最重要):
- 不替代 HNSW, 卡位运维三个具体痛点——

说(可解释)	trail 完整度 1.0	0.2	S5, V2 报告
删(合规)	物理释放 2.34MB	HNSW mark = 0	A3 报告
训(更新)	build 5.7s @ 50K	IVF 93.3s	S1 曲线

通用召回选 HNSW(尊重);

运维场景要可解释 / 能合规 / 敢重训——HNSW 答不出, GT+ 答得出。

金句: "HNSW 是赛车, GridTrace+ 是工程车——运维工地用的不是赛车。"

A6. PageIndex 11 项对比, 哪些主观?有客观数据吗?

- 答 (15s):
- 客观: 是否需要 Embedding([X]/[V])、是否需要 Vector DB([X]/[V])、检索延迟(PageIndex 850ms vs GT+ 1.73ms)、Token 消耗(树遍历 prompt 远超向量 query);
 - 主观: 增量写入、删除遗忘、百万级扩展、小模型友好(基于实现原理定性)。

没给 PageIndex 跑完整网格, 只跑了延迟 + Token 两个客观项。

主观项不参与 PK, 只展示差异。

A7. S3 SLA 30ms: GT+ 1.73ms vs HNSW 0.18ms, 慢 10 倍 — 这不是比 HNSW 慢吗?

- 答 (15s):
- 没错, GT+ 慢 10 倍。
- 但 1.73ms 远低于 30ms SLA 红线——慢 10 倍也合规。

金句: "1.73 vs 0.18, 人眼看不出; 1.73 vs 30, 人眼也看不出。SLA 不追极限, 追合格。"

A8. S5 Trail 完整度 1.0 vs 0.2 怎么评的?有人工打分吗?

答(20s):

自动评估, 无人工打分。

定义 retrieval_trail 的 5 个字段:

query → grid_hit → anchor_expand → entry_rerank → score_threshold → final_answer

- GT+: $5/5 = 1.0$
- Flat/IVF/HNSW: 只返回 final_answer = 0.2
- PageIndex: 返回 tree_path(2 字段) = 0.4

5x 不是拍脑袋, 是字段覆盖率 = $5/1 = 5.0$ 。

报告: docs/PARADIGM_BENCHMARK_V3_A3_REPORT.md A3 trail 章节。

A9. 跑对比花了多长时间?什么机器?

答(10s):

- 机器: 本地 i7-13700H / 32GB / 无 GPU (BGE 用 CPU 跑);
- 总耗时: V2 1584 组 $\approx 30\text{min}$, V3 216 组 $\approx 15\text{min}$;
- 全流程重跑 ≈ 1 小时。

金句: "一小时出全表, 可复现。"

A10. 为什么不跟最新 SOTA 比(2024 某 RAG)?

答(10s):

选 4 范式比的是路线差异(暴力 / 倒排 / 图 / 树), 不是"哪条路最新"。

SOTA 每年都有, 路线差异 30 年不变。任何新 SOTA 都能归到这 4 类之一。

B 篇 · 超参数实验调参(10 问)

答(15s):

默认参数是通用数据集训出来的:

- Faiss IVF: $nlist=4\sqrt{N}$ (适用 100 万级);
- hnswlib: $M=16$ (适用 768 维 BGE-large);

我们的场景:

- $N=50K$ (不是 100 万)
- 512 维 BGE-small(不是 768)
- 短文本(运维工单平均 50 字)

场景不同, 默认参数不适用, 必须场景化调参。

金句: "穿大一号鞋能走路, 但跑不快——调参就是量脚选码。"

B1.

B2. $\tau=0.65$ 换数据集还成立吗?会不会过拟合?

答(20s):

不一定,这是诚实声明。

- 0.65 是在我们 $332 + 80 = 412$ 条上调出来的;
- 换数据集(医疗 / 法律)甜蜜点会漂移;
- 调参方法可复用,具体值不通用。

校准流程(任何数据集可复用):

1. 标注集上画 τ -FPR 曲线;
2. 找 $FPR \leq 5\%$ 约束下的最低 τ ;
3. 留出集验证 Hit 下降 $< 2.5pp$ 。

金句:"0.65 是默认值,不是教条。生产有自调机制。"

B3. $L1-K=8$, 不能直接用 $L1-K=24$ 吗?延迟真差很多?

答(15s):

- 召回: $L1-K=8 = 0.95$; $L1-K=24 = 0.975 (+2.5pp)$;
- 延迟: $L1-K=8 = 1.73ms$; $L1-K=24 = 5.2ms (3 \text{ 倍})$;
- 精排计算量:3 倍候选,3 倍 cosine。

SLA 30ms 下两者都过,但 $L1-K=24$ 把精排从 $< 1ms$ 顶到 5ms,精排成瓶颈。

+2.5pp 召回换 +3.5ms 延迟,得不偿失。

报告 Fig. 3 $L1-K$ 敏感性曲线。

B4. $\epsilon=0.02$ 为什么不是 0.01 或 0.05?

答(15s):

ϵ 是量化步长(向量量化 $\rightarrow$ 整数 $\rightarrow$ 哈希锚点 ID):

- $\epsilon=0.01$:锚点太多(冗余),索引膨胀,粗筛慢;
- $\epsilon=0.05$:锚点太少(粗排失效),召回掉;
- $\epsilon=0.02$:1584 组里 Hit+FPR 帕累托最优(Fig. 4 平台区中心);

而且 $\epsilon \in [0.01, 0.10]$ 整段都是质量不变的平台——Hit 99.5%, FPR 12-13%。

金句:" ϵ 是宽容的——你随便选,我们不崩。"

B5. $Top-K=3$ 是不是太小?为什么不是 5 或 10?

答(15s):

$Top-K$ 是给 LLM 的候选数——

- K 太小:漏召;
- K 太大:token 暴涨、生成慢、上下文噪声多。

DeepSeek 单 query 1K tokens ≈ 0.001 ——

- $K=3 \rightarrow 0.003/query$

- $K=10 \rightarrow 0.010/\text{query}$ (3.3 倍)

1 万次/天:省 70/天 = 一年省 25,000。

金句: "K=3 是'够用就好', K=10 是'钱多任性'。"

B6. *为什么用网格不用贝叶斯 / 强化学习?

答(20s):

网格 = 4 维 $\times$ 5-10 档 $\approx$ 1 万组, 本机 1 小时跑完, 可承受。

贝叶斯:

- 黑盒: 看不到 τ 决定生死, L1-K 锦上添花"这种结构洞察;
- 收敛慢: 1 万组网格, 贝叶斯反而更久;
- 不利于复现: 每次跑结果有微差。

网格的好处是可视化:

- Fig. 1 τ 曲线 $\rightarrow$ 看到甜蜜点
- Fig. 2 $\tau \times$ L1-K 热力图 $\rightarrow$ 看到"安全带 vs 危险带"
- Fig. 3 L1-K 敏感性 $\rightarrow$ 看到膝盖点
- Fig. 4 ϵ 平台 $\rightarrow$ 看到参数宽容

金句: "贝叶斯出数字, 网格出认知。答辩要的是认知。"

B7. 1800 组怎么防止过拟合?有交叉验证吗?

答(15s):

三道防线:

1. 5 折交叉验证(V2 跑);
2. 留出 hard_confusion 集(80 条, 调参时完全不可见);
3. bootstrap 1000 次: FPR 95% CI [2.7%, 3.5%], 稳定。

验证结果:

- 训练集 Hit = 99.5%
- 留出集 Hit = 57.5%
- 真实部署 Hit 介于两者之间, 工程可接受

诚实声明: "hard 集 Hit=57.5% 是真实场景, 我们没藏。"

B8. 1800 组只跑了 GT+, 其他 4 范式也跑了同样网格吗?

答(15s, 诚实声明):

没跑。其他 4 范式只跑了"默认参数 + 我们推荐配置", 没做完整网格。

原因:

- 每范式超参空间不同 (IVF: nlist/nprobe; HNSW: M/ef; PageIndex: tree depth);
- 全做 4 范式 $\times$ 1 万组 = 4 万组, 本机 4 小时, 超边际;

- 我们证明 GT+ 自身最优, 不是跨范式 PK。

金句: "我们证明'我的鞋合脚', 不是'所有人都得穿我的鞋'。"

B9. 0.65 怎么验证?换 query 就崩了?

答(20s):

验证写在 rag_hyperparam_report_v3_joint.md 验证章节——

1. bootstrap 1000 次:FPR 95% CI [2.7%, 3.5%], 稳定;
2. 新 query 集(200 条现场工单, 2026-03 采集):FPR = 3.4%(在 CI 内);
3. τ 监控 + 自调:生产 7×24 监控 FPR, FPR > 8% 自动报警, 人工可调 τ 。

金句: "0.65 是默认值, 不是教条。生产有自调。"

B10. 调参里有没有调 LLM 的 temperature / prompt?为什么只调 RAG 端?

答(10s):

LLM 端固定:

- temperature=0.1(确定性, 适合运维);
- prompt 模板固定(角色 / 上下文 / 指令 三段式);
- 无 Key 兜底:返回原文, 绝不崩。

只调 RAG 端的原因:LLM 是"厨子", RAG 是"食材"——食材不好, 厨子再好也白搭。

答辩重点在 RAG(项目核心)。

C 篇 · 方法论 & 跨实验(5 问)

答(180s 简版, 备用):

"我们做了两组实验——

一组是范式对比:6 范式同场竞技, 证明 GridTrace+ 在 S5 trail 完整度 5 倍独享、A3 物理删除释放 2.34MB、build 比 IVF 快 16 倍;

另一组是超参调参:对 4 个超参做 1800 组网格, 得出 $\epsilon=0.02$ / L1-K=8 / $\tau=0.65$ / Top-K=3 的帕累托最优。

每一行配置都有数据撑腰, 没有拍脑袋。"

C2. *实验设计有统计学缺陷吗?

答(15s, 诚实):

有, 承认 3 个缺陷:

1. 样本量小:412 条 query, 统计功效有限;
2. 领域单一:只测了运维, 医疗 / 法律未验证;
3. 主观项:trail 完整度是字段覆盖率, 不是真正的人工评估。

改进方向(后续工作):

- A2 用户研究(30 人打分)正在进行;
- 跨领域 KB(法律 / 医疗)待扩展;
- trail 加 LLM-as-judge 评估。

C1. :

金句: "我们把缺陷写在 A3 报告最后一节——答辩要诚实, 不包装。"

C3. 老师问"1800 组对比的论文投哪里?"

- 答(10s):
- 目标:NLP 领域工坊 + 系统会议 (EMNLP System Demonstrations / SIGIR Demo / CIKM Short)。
- 不投主会 (NeurIPS / ACL):
- 工作偏系统工程不是纯算法;
 - 贡献是调参方法学 + 范式对比框架, 不是新模型;
 - 顶会偏好新方法而非新基准。

金句: "我们贡献的是测尺, 不是新刀。"

C4. "Flat 也只返回 ID, 说它没 trail 公平吗?"

- 答(10s):
- 公平。Flat 实质"返回 ID 列表", 无显式 trail 字段:
- Hit@1 exact:Top-1 ID = 答案 ID [v]
 - trail 完整度:无 query 改写、无 grid 命中、无 anchor 展开 = 0/5

Flat 的"暴力全比"过程在 CPU 里, 不出现在返回结果。
GridTrace+ 的"两阶段"过程显式写进 hit_trail JSON。

金句: "Flat 心里有数, GT+ 把数写在脸上——运维要'写在脸上'。"

C5. "PageIndex 延迟高多少?给个数字。"

- 答(10s):
- A2 报告实测(30 query 取平均):
- PageIndex:平均 850ms / query(树遍历 + LLM reasoning 多次);
 - GridTrace+:1.73ms / query;
 - 差距 490 倍。

这也是我们在延迟项上不主观打分, 直接给数据的原因。

报告: docs/PARADIGM_BENCHMARK_V3_A2_USER_STUDY.md

金句: "PageIndex 慢, 不是 2 倍, 是 490 倍。"

D 篇 · 速记卡片(贴讲稿背面, 10 秒抽一条)

为什么选这 4 个范式?	4 条技术路线各一个代表
GT+ 不如 HNSW 还用?	不抢赛道, 卡位运维三痛点
$\tau=0.65$ 换数据集还成立?	不一定, 校准方法可复用, 值不通用

为什么不调 LLM?	调食材不调厨子, 食材决定一切
为什么网格不用贝叶斯?	网格出认知, 贝叶斯出数字, 答辩要认知
1800 组会过拟合吗?	5 折 + 留出集 + bootstrap 三道防线
物理删除真删了?	mark_deleted=False 释放 2.34MB, A3 实测
为什么不调 HNSW 同样网格?	4 万组超边际, 证明"我的鞋合脚"不是 PK
实验有缺陷吗?	有, 3 个, 写在 A3 报告, 改进方向已列
PageIndex 慢多少?	850ms vs 1.73ms, 490 倍

E 篇 · 引用清单(老师问"出处在哪"直接念)

[V2-主]	docs/PARADIGM_BENCHMARK_V2_REPORT.md	S1-S5 决策树
[V3-A1]	docs/PARADIGM_BENCHMARK_V3_A1_REPORT.md	A1 多语言模型对比
[V3-A2]	docs/PARADIGM_BENCHMARK_V3_A2_USER_STUDY.md	A2 30 query × 5 范式
[V3-A3]	docs/PARADIGM_BENCHMARK_V3_A3_REPORT.md	A3 诚实修正 + trail 完整度
[V3-Phase1]	docs/PARADIGM_BENCHMARK_V3_PHASE1_REPORT.md	Phase 1 中期汇总
[HP-V2]	docs/rag_hyperparam_report.md	V2 1584 组调参
[HP-V3]	docs/rag_hyperparam_report_v3_joint.md	V3 joint 216 组 + 验证
[图-V2]	docs/paradigm_benchmark_v2_charts/	8 张:决策树 / 雷达 / 热力图 / 规模化 / SLA / 30 query
[图-HP]	docs/hyperparam_charts/	4 张:τ 权衡 / τ-L1K 热力图 / L1-K 敏感性 / 1000 组
[图-4范]	docs/rag4_charts/	3 张:trail 5x / build 16.4x / delete 2.34MB
[论文]	ICML 2025	Fast Exact Unlearning for In-Context Learning
[GT仓库]	github.com/guts-yang/GridTrace	开源版
[PI仓库]	github.com/VectifyAI/PageIndex	对比基准

F 篇 · 应急模板(老师突然问"未准备过的")

模板

"这个具体数字我现场没记下来,但可以引用 [docs/PARADIGM_BENCHMARK_V2_REPORT.md] 的 [章节] 给您查证。我优先保证已答过的精确,不现场编。"

模板 2:

"这块主要是我们组 [名字] 负责的,我了解思路但具体实现细节要问他。核心思想是 [简述一二三]。我们不抢答,也不搪塞。"

模板 3:

"您说的对,我们有这个缺陷——已在 A3 报告最后一节列了。改进方向是 [列 1-2 条]。答辩要诚实,不是包装。"

模板 4:

"实验可复现, python -m experiments.paradigm_benchmark.charts_hyperparam 一行命令, 1 小时出全表。欢迎老师会后看复现。"

模板 5:

"谢谢老师时间提醒。我最后一句收尾——[三会数字员工口号 + OpsWarden 名字 + 致谢]。"

准备完毕:5 大类 25 问, 3 张速记卡, 5 个应急模板, 13 个引用出处。 总预备时间:约 30 分钟熟读 + 1 小时模拟答辩 = 1.5 小时。 建议:打印 A、B、C 三篇核心(30 张 A4 单面), 讲稿放桌面, 被问时翻对应字母 + 问题号。